دانشگاه صنعتی خواجه نصیرالدین طوسی

دانشکده مهندسی صنایع

مدل انتخاب سبد سرمایه‌گذاری مبتنی بر پیش‌بینی با استفاده از ماشین بردار پشتیبان

محمدامین منادی

استاد راهنما:

دکتر امیر عباس نجفی

پایان نامه کارشناسی ارشد

رشته مهندسی صنایع گرایش مهندسی مالی

شهریور ۱۴۰۰

بسم الله الرحمن الرحيم

الحمد لله رب العالمين الرحمن الرحيم مالك يوم الدين
اياك نعبد واياك نستعين اهدنا الصراط المستقيم
صراط الذين انعمت عليهم غير المغضوب عليهم
ولا الضالين

تقدیم با بوسه بر دستان پدرم :

به او که نمی دانم از بزرگی اش بگویم یا مردانگی، سخاوت، سکوت، مهربانی و . . .

پدرم راه تمام زندگیست

پدرم دلخوشی همیشگیست

تقدیم به مادر عزیزتر از جانم :

مادرم ،هستی من ز هستی توست تا هستم و هستی دارمت دوست

گلکسار جاودانی مادر است

چشم سار مهربانی مادر است

تاسیس ۱۳۰۷ دانشگاه صنعتی خواجه نصیرالدین طوسی	**تأییدیه هیأت داوران**	**شماره:** **تاریخ:**

هیأت داوران پس از مطالعه پایان نامه و شرکت در جلسه دفاع تهیه شده تحت عنوان:

مدل انتخاب سبد مبتنی بر پیش‌بینی با استفاده از ماشین بردار پشتیبان

توسط آقای/ خانم **محمد امین منادی**، صحت و کفایت تحقیق انجام شده را برای اخذ درجه کارشناسی ارشد در رشته **مهندسی صنایع** گرایش **مهندسی مالی** در تاریخ ۱۴۰۰/۰۶/۳۱ مورد تأیید قرار می‌دهند.

۱- استاد راهنما	جناب آقای **دکتر امیرعباس نجفی**	**امضاء**
۲- استاد مشاور	جناب آقای/ سرکار خانم	**امضاء**
۳- ممتحن داخلی	جناب آقای **دکتر مجید میرزایی**	**امضاء**
٤- ممتحن خارجی	جناب آقای **دکتر مجید شیخ محمدی**	**امضاء**
٥- معاونت آموزشی و تحصیلات تکمیلی دانشکده	جناب آقای **دکتر رضا رمضانیان**	**امضاء**

تاسیس ۱۳۰۷ دانشگاه صنعتی خواجه نصیرالدین طوسی	**اظهارنامه دانشجو**	**شماره:** **تاریخ:**

اینجانب **محمدامین منادی** دانشجوی کارشناسی ارشد رشته **مهندسی صنایع** گرایش **مهندسی مالی** دانشکده مهندسی صنایع دانشگاه صنعتی خواجه نصیرالدین طوسی گواهی می‌نمایم که تحقیقات ارائه شده در پایان نامه با عنوان **مدل انتخاب سبد مبتنی بر پیش‌بینی با استفاده از ماشین بردار پشتیبان** با راهنمایی استاد محترم جناب آقای دکتر **امیر عباس نجفی،** توسط شخص اینجانب انجام شده و صحت و اصالت مطالب نگارش شده در این پایان نامه مورد تأیید می‌باشد، و در مورد استفاده از کار دیگر محققان به مرجع مورد استفاده اشاره شده است. بعلاوه گواهی می‌نمایم که مطالب مندرج در پایان نامه تاکنون برای دریافت هیچ نوع مدرک یا امتیازی توسط اینجانب یا فرد دیگری در هیچ جا ارائه نشده است و در تدوین متن پایان نامه چارچوب (فرمت) مصوب دانشکده مهندسی صنایع را بطور کامل رعایت کرده‌ام. چنانچه در هر زمان خلاف آنچه گواهی نموده‌ام مشاهده گردد خود را از آثار حقیقی و حقوقی ناشی از دریافت مدرک کارشناسی ارشد محروم می‌دانم و هیچگونه ادعائی نخواهم داشت.

امضاء دانشجو:

تاریخ:

تاسیس ۱۳۰۷ دانشگاه صنعتی خواجه نصیرالدین طوسی	**حق طبع و نشر و مالکیت**	**شماره:** **تاریخ:**

۱- حق چاپ و تکثیر این پایان نامه متعلق به نویسنده و استاد راهنمای آن می‌باشد. هر گونه کپی برداری بصورت کل پایان نامه یا بخشی از آن تنها با موافقت نویسنده یا استاد راهنما یا کتابخانه دانشکده مهندسی صنایع دانشگاه صنعتی خواجه نصیرالدین طوسی مجاز می‌باشد.

ضمناً متن این صفحه نیز باید در نسخه تکثیر شده وجود داشته باشد.

۲- کلیه حقوق معنوی این اثر متعلق به دانشگاه صنعتی خواجه نصیرالدین طوسی می‌باشد و بدون اجازه کتبی دانشگاه به شخص ثالث قابل واگذاری نیست.

همچنین استفاده از اطلاعات و نتایج موجود در پایان نامه بدون ذکر مراجع مجاز نمی‌باشد.

* توجه:

این فرم می‌بایست پس از تکمیل، در نسخ تکثیر شده قرار داده شود.

پروردگار را سپاسگزارم که بار دیگر به من فرصت آموختن داد.

از پدر و مادر عزیز و مهربانم به خاطر زحماتی که در طول زندگی همواره برای پیروزی و شادکامی من به جان خریدند، تشکر می کنم.

همچنین از استاد بزرگوار، جناب آقای دکتر امیرعباس نجفی، بابت راهنمایی ها، حسن سلوک و حمایت بی دریغ ایشان تشکر کرده و

برای ایشان طول عمر توام با سربلندی را آرزومندم.

چکیده

با رشد و توسعه اقتصاد جهانی و رقابتی شدن آن، تصمیم‌گیری در رابطه با تخصیص بهینه منابع بیش از پیش اهمیت پیدا نموده است. بورس اوراق بهادار علاوه بر آن که آئینه تمام نمای وضعیت اقتصادی کشورها بوده، مکانی برای سرمایه‌گذاران است که بتوانند منابع خود را در آن سرمایه‌گذاری کنند تا ثروت خود را افزایش دهند. از آنجا که کاهش ریسک و افزایش بازده سرمایه‌گذاری در بازار سهام همواره مهم‌ترین و اساسی‌ترین دغدغه سرمایه‌گذاران بوده، در ادبیات مالی، سرمایه‌گذاری در سبد سهام به منظورکاهش ریسک پیشنهاد شده است. از سوی دیگر یکی از عوامل مؤثر در تصمیم‌گیری‌های سرمایه‌گذاری، قیمت سهام بوده و انتخاب سبد سهام به عنوان یک برنامه سرمایه‌گذاری علاوه بر آن که باید ماحصل گذشته سهام را در بربگیرد، باید پتانسیل آتی سهام را نیز در نظر بگیرد، لذا اهمیت پیش‌بینی قیمت سهام بیش از پیش آشکار می‌گردد. به علت اینکه بازار سهام اساساً پویا، پیچیده، غیرخطی و غیرپارامتریک است و از تعداد بسیاری از عوامل و متغیرهای اقتصادی و غیراقتصادی متأثر بوده، همواره از گذشته تاکنون انتخاب بهترین وکارآمدترین مدل به منظور پیش‌بینی ماهیت غیرخطی داده‌های سهام امری ضروری، دشوار و چالش برانگیز است. علاوه بر آن، پژوهشات گذشته نشان می‌دهد که استفاده از روش‌های پیش‌بینی سنتی، دارای خطای بالاتر و عملکرد ضعیف‌تر در مقایسه با روش‌های جدیدتر و مدل‌های غیرخطی می‌باشند. در همین راستا، در این پژوهش یکی از روش‌های هوش مصنوعی با عنوان رگرسیون بردار پشتیبان با خروجی چندگانه به منظور پیش‌بینی قیمت سهام، به کار گرفته شده و در ادامه با داده‌های پیش‌بینی شده به بهینه سازی سبد سهام پرداخته شده است. در انتها نتایج حاصل با نتایج حاصل از انتخاب بهینه سبد سهام مبتنی بر پیش‌بینی با رگرسیون بردار پشتیبان ساده مورد قیاس قرار گرفته است.

واژگان کلیدی: انتخاب سبد، پیش‌بینی قیمت سهام، رگرسیون بردار پشتیبان، رگرسیون با خروجی چندگانه

فهرست مطالب

فصل اول: مقدمه و کلیات تحقیق ۱

۱-۱- مقدمه ۲

۱-۲- تعریف مسئله ۳

۱-۳- اهداف پژوهش ۵

۱-۴- اهمیت موضوع ۶

۱-۵- پرسش‌ها و سؤالات اصلی تحقیق ۷

۱-۶- متدولوژی تحقیق ۷

۱-۷- کاربردهای پژوهش ۸

۱-۸- چارچوب تحقیق ۸

فصل دوم: بیان مفاهیم و مرور ادبیات ۹

۲-۱- مقدمه ۱۰

۲-۲- سرمایه‌گذاری ۱۰

۲-۳- ماهیت اصلی تصمیمات سرمایه‌گذاران ۱۱

۲-۳-۱- بازده ۱۱

۲-۳-۲- ریسک ۱۳

۲-۳-۲-۱- ریسک غیر سیستماتیک (کاهش پذیر یا قابل اجتناب) ۱۳

۲-۳-۲-۲- ریسک سیستماتیک (کاهش ناپذیر یا غیر قابل اجتناب) ۱۴
۲-۴- پرتفوی ۱۴
۲-۴-۱- بهینه‌سازی پرتفوی ۱۴
۲-۴-۲- تنوع بخشی و بازده ۱۸
۲-۵- یادگیری و انواع آن ۱۹
۲-۵-۱- یادگیری با نظارت ۲۰
۲-۵-۲- یادگیری بدون نظارت ۲۰
۲-۶- ماشین بردار پشتیبان ۲۰
۲-۷- رگرسیون بردار پشتیبان ۳۴
۲-۶- مروری بر ادبیات موضوع ۳۷
۲-۷- جمع‌بندی ۴۳
فصل سوم: روش شناسی تحقیق ۴۴
۳-۱- مقدمه ۴۵
۳-۲- روش تحقیق ۴۵
۳-۳- جامعه و نمونه آماری تحقیق ۴۶
۳-۴- دوره زمانی مورد بررسی تحقیق ۴۶
۳-۴- روش گردآوری اطلاعات ۴۷

۳-۷- ابزار مورد استفاده در انجام تحقیق ۴۷

۳-۸- ماشین بردار پشتیبان با خروجی چندگانه ۴۷

۳-۹- رگرسیون بردار پشتیبان حداقل مربعات ۴۹

۳-۹-۱- رگرسیون بردار پشتیبان حداقل مربعات با خروجی چندگانه ۴۹

۳-۱۰- جمع‌بندی و نتیجه‌گیری ۵۳

فصل چهارم: تجزیه و تحلیل داده‌ها و اطلاعات ۵۴

۴-۱- مقدمه ۵۵

۴-۲- پیش‌بینی بازده آتی سهام با رگرسیون بردار پشتیبان ۵۵

۴-۳- حل مسئله انتخاب سبد سهام بهینه ۶۱

۴-۴- مقایسه نتایج حل دو مدل ارائه شده با یکدیگر ۶۶

۴-۵- جمع بندی ۶۷

فصل پنجم: نتیجه‌گیری و پیشنهادات برای تحقیقات آتی ۶۹

۵-۱- مقدمه ۷۰

۵-۲- جمع بندی تحقیق ۷۰

۵-۳- خلاصه‌ای از پایان نامه ۷۱

۵-۴- پیشنهادات برای تحقیقات آتی ۷۲

فهرست منابع ۷۳

فهرست جداول

جدول ۲-۱- خلاصه‌ای از مقالات منتخب خارجی..... ۴۰

جدول ۲-۲- خلاصه‌ای از مقالات منتخب داخلی..... ۴۰

جدول ۴-۱- اسامی و ترتیب سهام به همراه صنایع مربوطه..... ۵۶

جدول ۴-۲- خطای پیش‌بینی حاصل از دو رویکرد ۵۷

جدول ۴-۵- خطای پیش‌بینی حاصل از دو رویکرد ۵۸

جدول ۴-۶- ماتریس واریانس کوارایانس حاصل از تفاضل داده‌های واقعی و پیش‌بینی (پیش‌بینی ساده) ۶۲

جدول ۴-۷- ماتریس واریانس کوارایانس حاصل از تفاضل داده‌های واقعی و پیش‌بینی (پیش‌بینی چندگانه) ۶۲

جدول ۴-۸- سناریوهای ایجاد شده برای حداقل بازده مورد نیاز در آخرین هفته (پیش‌بینی چندگانه) ۶۳

جدول ۴-۹- سناریوهای ایجاد شده برای حداقل بازده مورد نیاز در آخرین هفته (پیش‌بینی ساده)..... ۶۵

جدول ۴-۱۰- مقایسه نسبت‌های شارپ ۶۸

فهرست اشکال

شکل ۱-۱- انواع مسائل دسته‌بندی از نظر تعداد و سطوح.....۵

شکل ۲-۱- انواع ریسک پرتفوی..... **۱۳**

شکل ۲-۲- نمونه‌ای از مرز کارا مؤثر ۱۶

شکل ۲-۳- نمایی از ابرصفحه جداساز با در نظر گرفتن حداکثر حاشیه برای دو طبقه..... ۲۱

شکل ۲-۴- تفکیک داده‌ها در فضا توسط ابر صفحه‌های متفاوت..... ۲۲

شکل ۲-۵- ابر صفحه‌ای که بیشترین فاصله را دارا می‌باشد، با جابجایی داده و کاهش دقت بهینه‌تر و مناسب‌تر بنظر می‌رسد..... ۲۲

شکل ۲-۶- نمونه‌ای از ماشین بردار پشتیبان با حاشیه سخت، که هیچ خطای آموزشی ندارد..... ۲۴

شکل ۲-۷- نمونه‌ای از ماشین بردار پشتیبان با تفکیک ناپذیر ۲۸

شکل ۲-۸- ماشین بردار پشتیبان غیرخطی..... ۳۲

شکل ۲-۹- رگرسیون بردار پشتیبان ۳۴

شکل ۲-۱۰- نمودار پراکندگی مطالعات بهینه سازی سبد سرمایه‌گذاری..... ۳۹

شکل ۳-۱- چارچوب روش تحقیق..... ۴۴

شکل ۳-۲- مثالی از درک اصول رگرسیون بردار پشتیبان حداقل مربعات با خروجی چندگانه..... ۵۰

شکل ۴-۱- روند قیمتی در سهام منتخب در بازه زمانی ۲۰۱۶/۱۲/۰۹ تا ۲۰۲۱/۰۲/۰۸..... ۵۷

شکل ۴-۲- روند بازده در سهم منتخب در بازه زمانی ۲۰۲۰/۱۳/۰۷ تا ۲۰۲۱/۰۲/۰۸..... ۵۹

شکل ۴-۳- روند بازده در سهم منتخب در بازه زمانی ۲۰۲۰/۱۳/۰۷ تا ۲۰۲۱/۰۲/۰۸..... ۵۹

شکل ۴-۴- روند بازده در سهم منتخب در بازه زمانی ۲۰۲۰/۱۳/۰۷ تا ۲۰۲۱/۰۲/۰۸..... ۵۹

شکل ۴-۵- روند بازده در سهم منتخب در بازه زمانی ۲۰۲۰/۱۳/۰۷ تا ۲۰۲۱/۰۲/۰۸ ..... ۶۰
شکل ۴-۶- روند بازده در سهم منتخب در بازه زمانی ۲۰۲۰/۱۳/۰۷ تا ۲۰۲۱/۰۲/۰۸ ..... ۶۰
شکل ۴-۷- روند بازده در سهم منتخب در بازه زمانی ۲۰۲۰/۱۳/۰۷ تا ۲۰۲۱/۰۲/۰۸ ..... ۶۰
شکل ۴-۸- روند بازده در سهم منتخب در بازه زمانی ۲۰۲۰/۱۳/۰۷ تا ۲۰۲۱/۰۲/۰۸ ..... ۶۱
شکل ۴-۹- مزر کارا با استفاده از رگرسیون بردار پشتیبان چندگانه ۶۴
شکل ۴-۱۰- مزر کارا با استفاده از رگرسیون بردار پشتیبان یکتا ۶۴
شکل ۴-۱۱- مقایسه مزر کارا دو رویکرد ۶۴

فصل اول

مقدمه و کلیات تحقیق

۱-۱- مقدمه

انسان همواره در زندگی خویش به دنبال پیشرفت اقتصادی و افزایش درآمد بوده و یکی از راه‌های رسیدن به این هدف سرمایه‌گذاری مناسب است. از این رو انتخاب بهینه سبد سرمایه‌گذاری به عنوان یکی از مهم‌ترین مسائل مالی همواره مطرح بوده است، طوری که این انتخاب کمترین ریسک و بیشترین بازده را شامل گردد. بر همین اساس همواره مدل‌هایی به منظور انتخاب سبد سهام بهینه در جهت برطرف کردن نواقص پیشین و بهبود نتایج حاصل از آنان معرفی می‌شوند و تلاش دارند اهداف موردنظر سرمایه‌گذاران را به به بهترین نحو برآورده سازند. در این فصل کلیاتی در رابطه با پایان نامه من جمله: بیان مسئله، اهداف پژوهش، اهمیت تحقیق و پرسش‌های اصلی پژوهش بیان می‌گردد.

۱-۲- تعریف مسئله

مسئله انتخاب سبد سرمایه‌گذاری و بهینه‌سازی، یکی از مسائل مهمی است که سرمایه‌گذاران همیشه با آن رو به رو بوده و به دنبال بهترین عملکرد هستند تا بتوانند با بیشترین بازده ممکن، کمترین عدم قطعیت را متحمل شوند و مطلوبیت سبد را حداکثر کنند. این موضوع معادل با انتخاب سبد سهام بهینه از مجموعه‌ای از سهام‌های ممکن است که تحت عنوان انتخاب سبد[۱] سهام نامیده شده است. این سنجه‌های عدم قطعیت که ریسک نام دارند، موجب مقایسه گزینه‌های سرمایه‌گذاری می‌شوند. ویژگی مذکور هسته اصلی نظریه پرتفوی مدرن[۲] می‌باشد. این نظریه را هری مارکویتز[۳] از طریق مدل مشهور انتخاب پرتفوی بیان نمود. در این مدل ریسک کل سرمایه‌گذاری از طریق انتخاب بهینه سهام مختلف و تنوع بخشی[۴]کمینه می‌شود. فرآیند انتخاب پرتفوی عبارت است از یافتن سهام با ریسک مشترک کم در یک مجموعه بزرگی از سهام، طوریکه ریسک پرتفوی در یک بازده معین حداقل یا بازده پرتفوی با یک ریسک معین حداکثر می‌گردد. در این مدل فرض می‌گردد که سری‌های زمانی دارای توزیع نرمال بوده و بازده مورد انتظار، میانگین بازده‌های تاریخی می‌باشد (فریتاس و همکاران، ۲۰۰۶). از طرفی توزیع سری‌های زمانی اغلب چولگی[۵] وکشیدگی[۶] را نیز نشان می‌دهند که مغایر با فرض مدل‌های کلاسیک مبتنی بر نرمال بودن است و میانگین بازده‌های تاریخی تنها در دورهٔ سرمایه‌گذاری بلندمدت برابر با بازده مورد انتظار است (فریتاس و همکاران[۷]، ۲۰۰۶). همچنین انتخاب سبد سهام به عنوان یک برنامه سرمایه‌گذاری علاوه بر ماحصل گذشته سهام، باید پتانسیل آتی سهام را نیز در نظر بگیرد و کسانی در رقابت به پیروزی رسیده‌اند که بتوانند حداقل اطلاعاتی از آینده در خصوص تصمیم‌گیری داشته باشند اما آگاهی از

---

[۱] Portfolio Selection
[۲] Modern Portfolio Theory (MPT)
[۳] Harry Markowitz
[۴] Diversification
[۵] Skewness
[۶] Kurtosis
[۷] Freitas et al.

تصمیمات و دستاوردهای مربوط به آینده، همواره با عدم اطمینان و ابهام رو به رو بوده است (حبیب زاده و همکاران، ۱۳۹۷). از سویی به علاوۀ پیش‌بینی قیمت سهام، انتخاب بهترین و کارآمدترین مدل به منظور پیش‌بینی با توجه به تأثیرپذیری از تعداد بسیار زیادی از عوامل و متغیرهای اقتصادی و غیراقتصادی، پویایی، غیرخطی، پیچیدگی و غیرپارامتریک بودن همواره از گذشته تاکنون امری مهم و چالش برانگیز بوده و حتی برای برخی از محققان مهم‌ترین قسمت از علم اقتصادسنجی، پیش‌بینی است (دانا و همکاران، ۱۳۹۶). بنابراین با توجه به اهمیت پیش‌بینی در سرمایه‌گذاری و خطای بالاتر و عملکرد ضعیف‌تر روش‌های پیش‌بینی کلاسیک، مدل‌های پیش‌بینی بر اساس آنالیز سری‌های زمانی و روش‌های غیرخطی توسعه داده شده است. یکی از این روش‌ها، رگرسیون بردار پشتیبان می‌باشد (فتوره‌چیان و همکاران، ۱۳۹۲). این روش به دلیل عملکرد مناسب مورد استقبال و توسعه قرار گرفته و یکی از مدل‌های توسعه یافته آن رگرسیون بردار پشتیبان با خروجی چندگانه بوده، که به دلیل در نظرگرفتن روابط بین خروجی‌ها، دقت بالاتر و خطای پیش‌بینی پایین‌تری را دارا می‌باشد. در این پژوهش نیز به دنبال آن هستیم که با داده‌های پیش‌بینی‌شده با خطای کمتر نسبت به مدل ساده، سبد سهام با عملکرد بهتری را تشکیل دهیم. ماشین بردار پشتیبان، دسته‌بندی[۸] یک روش یادگیری با نظارت[۹] است که مدل برای تعیین متغیر(های) خروجی با استفاده از متغیرهای ورودی ساخته می‌شود. اگر متغیرهای خروجی گسسته باشند، در ادبیات موضوع یک مسئله دسته‌بندی نامیده شده و در صورت پیوسته بودن، یک مسئله پیش‌بینی نامیده می‌شود (ندایی و نجفی، ۱۳۹۷) (برچانی[۱۰]، ۲۰۱۵). انواع مسائل دسته‌بندی در شکل ۱-۱ نشان داده شده است.

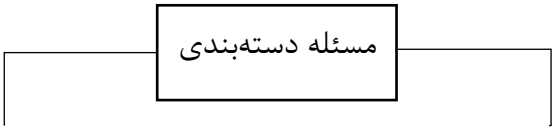

[۸] Classification
[۹] Supervised learning
[۱۰] Borchani

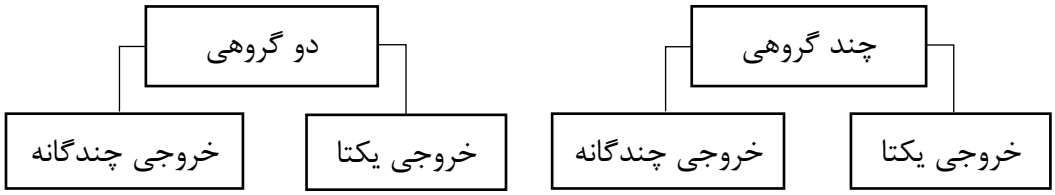

شکل ۱-۱- انواع مسائل دسته‌بندی از نظر تعداد و سطوح

رگرسیون بردار پشتیبان نیز یک رویکرد ناپارامتری می‌باشد که در آغاز برای مسائل پیش‌بینی تک خروجی ارائه شد. با توجه به موفقیت‌های بسیار ابزار مذکور، محققان آن را برای مسائل پیش‌بینی چند خروجی توسعه داده و بکار برده‌اند. در این میان مسئله پیش‌بینی با خروجی چندگانه که عبارت است از آموزش چند تابع، که هر تابع به یک متغیر خروجی تعلق دارد و زمانی که بین متغیرهای خروجی نوعی وابستگی برقرار باشد، با وجود مزایای این ابزار، روابط بین متغیرهای خروجی نادیده گرفته شده‌اند (ژو و همکاران[۱۱]، ۲۰۱۳). تحقیق جاری به دنبال انتخاب سبد سهام مبتنی بر پیش‌بینی با استفاده از رگرسیون با خروجی چندگانه به صورت همزمان می‌باشد، تا روابط بین خروجی‌ها را در نظر بگیرد. بدین ترتیب، پیش‌بینی قیمت سهام مبتنی بر این روش و انتخاب بهینه سهام، اصلی‌ترین مباحث موجود در این پژوهش خواهند بود.

۱-۳- اهداف پژوهش

در راستای تحقیقات و مطالعات صورت گرفته، برخی از روش‌های حاضر در ادبیات موجود دارای محدودیت بوده، که در این میان رگرسیون بردار پشتیبان به عنوان یکی از ابزارهای هوشمند در زمینه پیش‌بینی تنها برای مسائلی با یک خروجی[۱۲] بکار گرفته می‌شود که همین امر یکی از محدودیت‌های این روش می‌باشد. از سوی دیگر بدلیل موفقیت‌های این ابزار و انعطاف‌پذیری آن در مواجه با داده‌های مختلف، تحقیق جاری بر روی

[۱۱] Xu et al.
[۱۲] Single output

رگرسیون بردار پشتیبان در حالت چند خروجی[۱۳] به طور همزمان به منظور پیش‌بینی با دقت بالاتر و انتخاب سبد سهام با عملکرد بهتر تمرکز خواهد نمود.

۱-۴- اهمیت موضوع

پیش‌بینی قیمت سهام به علت تأثیرپذیری از تعداد بسیاری از عوامل و متغیرهای اقتصادی و غیراقتصادی همواره از گذشته تاکنون امری مهم و چالش برانگیز بوده، به طوری که انتخاب بهترین و کارآمدترین مدل به منظور پیش‌بینی ماهیت غیرخطی داده‌های سهام امری ضروری، دشوار و چالش برانگیز است (آقایی فر، ۱۳۹۸). تشکیل یک سبد سهام مبتنی بر پیش‌بینی یک کار چالش برانگیز دیگر است. لذا پیش‌بینی قیمت سهام و همچنین سرمایه‌گذاری در سهام مناسب همیشه در کانون توجه سرمایه‌گذاران، صنعتگران و دانشگاهیان بوده است. از این روی، روش‌هایی از قبیل رگرسیون بردار پشتیبان در ادبیات موضوع معرفی گردیده‌اند که به عنوان مدل‌های هوشمند[۱۴] شناخته شده‌اند (راسر و همکاران[۱۵]، ۲۰۱۷). ژو و همکاران (۲۰۱۳) در پژوهش خود ماشین بردار پشتیبان را جهت دسته‌بندی یا پیش‌بینی چند خروجی به طور همزمان ارائه می‌دهند. روش سنتی این روش شامل بکارگیری چندین ماشین برای حل چنین مسائلی است که عیب آن نادیده گرفتن روابط و وابستگی بین خروجی‌ها می‌باشد. تاکنون پژوهشی در رابطه با بهینه سازی سبد سهام مبتنی بر پیش‌بینی با استفاده از ابزار رگرسیون بردار پشتیبان با خروجی چندگانه به منظور در نظر گرفتن روابط بین متغیرهای خروجی ارائه

[۱۳] Multi-output
[۱۴] Artificial Intelligence
[۱۵] Rather et al.

نشده است. همین واقعیت و خلأ تحقیقاتی، اهمیت پرداختن به موضوع و انگیزه اصلی این پژوهش را آشکار می‌سازد.

۱-۵- پرسش‌ها و سؤالات اصلی تحقیق

پژوهش جاری با طرح ایده تشریح داده شده، سعی در یافتن پاسخ به برخی سؤالات مرتبط در این زمینه دارد.

- مدل‌سازی یک رگرسیون برای پیش‌بینی خروجی‌ها به طور همزمان به چه طریق ممکن است؟
- روش سنتی که از چندین رگرسیون بردار پشتیبان استفاده می‌کند و بصورت همزمان آنان را در نظر نمی‌گیرد دارای چه معایبی می‌باشد؟
- آیا انتخاب پرتفوی مبتنی بر این روش نسبت به روش سنتی خود دارای عملکرد بهتری می‌باشد؟

۱-۶- متدولوژی تحقیق

در این پژوهش با استفاده از رگرسیون بردار پشتیبان، برای حل مسئله، مدل رگرسیون با خروجی چندگانه به صورت همزمان ارائه خواهد شد که تا جای ممکن بتواند روابط بین متغیرهای خروجی را در نظر بگیرد و خطای پیش‌بینی کاهش یابد. در ادامه به انتخاب بهینه سهام با استفاده از نتایج پیش‌بینی پرداخته و عملکرد پرتفوی حاصل را به کمک معیار شارپ با پرتفوی بدست آمده از مدل سنتی رگرسیون بردار پشتیبان مورد مقایسه قرار خواهیم داد.

۱-۷- کاربردهای پژوهش

همان‌طور که سرمایه‌گذاری در بازارهای مالی، همواره مورد علاقه بسیاری از سرمایه‌گذاران بوده است، با توجه به عدم اطمینانی که در دنیای واقعی حاکم می‌باشد، پیش‌بینی قیمت به منظور دستیابی به بازده بیشتر با ریسک کمتر می‌تواند کاربرد بسیار وسیعی در مباحث عملی داشته باشد و سرمایه‌گذاران را در انتخاب سبدی بهینه به صورت چشم‌گیری یاری نماید.

۱-۸- چارچوب تحقیق

در این فصل سعی گردید کلیاتی در باب موضوع پژوهش ارائه گردد و اهداف پژوهش و اهمیت موضوع در آن مطرح و ضرورت، انگیزه و علت انتخاب موضوع ذکر شد. فصل دوم به توصیف مفاهیم و اصول سرمایه‌گذاری و موضوع ماشین بردار پشتیبان پرداخته و در آخر مرور کلی بر ادبیات و پیشینه پژوهش در زمینه انتخاب سبد سهام مبتنی بر پیش‌بینی مطرح می‌شود. در فصل سوم به روند اجرای موضوع و حله مسئله با در نظر گرفتن داده‌های در دسترس پرداخته خواهد شد. در فصل چهارم نیز نتایج حاصل از عملکرد روش مذکور، مورد ارزیابی و اعتبارسنجی قرار می‌گیرد. در فصل پنجم جمع‌بندی و پیشنهاداتی در زمینه پژوهش‌های آتی ارائه خواهد شد.

فصل دوم

بیان مفاهیم و مرور ادبیات

۲-۱- مقدمه

در فصل جاری، ابتدا به معرفی و توضیح مفاهیم و شاخه‌های مرتبط با موضوع پرداخته و در ادامه به دیدگاه‌ها و روش‌هایی که محققین پیشین در حوزه انتخاب بهینه سبد سهام مبتنی بر پیش‌بینی پرداخته‌اند اشاره شده تا ابعاد کلی موضوع تحقیق روشن شده و خلأ تحقیقاتی موجود نیز بررسی گردد و در فصول بعدی چارچوب مورد نیاز برای حل مسئله استخراج گردد.

۲-۲- سرمایه‌گذاری

سرمایه‌گذاری اصطلاحی است با چندین معنی مرتبط در مدیریت بازرگانی، مالی و اقتصاد در رابطه با پس‌انداز یا به تعویق انداختن مصرف. سرمایه‌گذاری انتخابی است که فرد سرمایه‌گذار پس‌انداز خود را با امید سود به خطر می‌اندازد. به عبارتی، به جای ذخیره کالا یا معادل پول آن کالا، سرمایه‌گذار ترجیح می‌دهد آن کالا ذخیره شده یا پول را به ازای سود یا قسمتی از سود قرض دهد (فیشر و جردن[۱]، ۱۹۸۷). به طور کلی، سرمایه‌گذاری عبارت است از تبدیل نمودن وجوه مالی به چندین نوع دارایی که برای مدت زمانی نگهداری خواهند شد (آزادی

[۱] Fischer & Jordan

و نجفی،۱۳۹۷). فرآیند سرمایه‌گذاری به چگونگی اقدام سرمایه‌گذاران در رابطه با اوراق بهاداری که سرمایه‌گذاری می‌کنند و میزان و زمان آن مرتبط است. یکی از روش‌های فرآیند سرمایه‌گذاری شامل مراحل تعیین سیاست‌های سرمایه‌گذاری، تجزیه و تحلیل اوراق بهادار، تشکیل یک سبد سرمایه‌گذاری، تجدید نظر و ارزیابی عملکرد سبد سرمایه‌گذاری است. رویکرد دیگر فرآیند سرمایه‌گذاری شامل تجزیه و تحلیل و مدیریت پرتفوی می‌باشد. تجزیه و تحلیل اوراق بهادار به معنی تخمین عایدی‌های هر کدام از اوراق می‌باشد و مدیریت پرتفوی نیز به معنی تجزیه و تحلیل ترکیب اوراق، مدیریت و نگهداری مجموعه‌ای از اوراق می‌باشد (اسدی و بیات، ۱۳۹۶).

۲-۳- ماهیت اصلی تصمیمات سرمایه‌گذاران

یکی از مفاهیم کلیدی در مدیریت سرمایه‌گذاری بازده و ریسک می‌باشد. سرمایه‌گذار برای تصمیم‌گیری در مورد سرمایه‌گذاری در یک دارایی لازم است از یک طرف بازده مورد انتظار خود را با توجه به عوامل مختلفی مانند ریسک آن دارایی تعیین کرده و از طرفی دیگر بتواند نرخ بازده آن را پیش‌بینی کند. طبیعتاً اگر نرخ بازده پیش‌بینی برای یک دارایی از نرخ بازده مورد انتظار بیشتر باشد، سرمایه‌گذار اقدام به سرمایه‌گذاری می‌کند و در غیر این صورت از خرید آن دارایی خودداری می‌نماید (احمدی و همکاران، ۱۳۹۳).

۲-۳-۱- بازده

بازده عبارت است از عایدی که از سرمایه‌گذاری در یک دارایی در طی یک دوره زمانی مشخص بدست می‌آید. یک دارایی ممکن است از دو طریق برای سرمایه‌گذار عایدی ایجاد کند: تولید جریان نقدی و افزایش قیمت

خود دارایی. بخش اول ناشی از سود تقسیمی[۲] سهام و بخش دوم ناشی از افزایش قیمت خود دارایی است. حال فرض کنید دارایی در زمان $t = ۰$ به قیمت $P_۰$ خریداری شود و تا زمان $t = H$ نگهداری گردد. در این مدت، درآمد نقدی ناشی از سرمایه‌گذاری (مثلاً درآمد اجاره برای مسکن یا سود سهام تقسیمی) برابر D_H بوده و در پایان دوره با قیمت P_H به فروش می‌رسد. در این صورت، نرخ بازده در طی دوره نگهداری برابر خواهد بود با:

$$r = \frac{P_H + D_H}{P_۰} - ۱ \qquad (۱-۲)$$

و یا:

$$r = \frac{P_H - P_۰}{P_۰} + \frac{D_H}{P_۰} \qquad (۲-۲)$$

در رابطه بازده دوره نگهداری[۳]، در زمان $t = ۰$ یعنی ابتدای دوره سرمایه‌گذاری، درآمد نقدی (D_H) و قیمت فروش (P_H) برای سرمایه‌گذار مشخص نیست و وی تنها می‌تواند با توجه به اطلاعات خود تخمینی از این دو کمیت داشته باشد. اگر بازده دوره نگهداری را به کمک مقادیر تخمینی یا مورد انتظار بدست آوریم، به آن بازده دوره نگهداری مورد انتظار یا بازده مورد انتظار[۴] گفته می‌شود. اگر پس از زمان $t = H$ یا به عبارتی پایان دوره سرمایه‌گذاری و تعیین شدن مقادیر P_H و D_H بازده دوره نگهداری را حساب کنیم به آن بازده دوره نگهداری تحقق یافته یا بازده تحقق یافته[۵] گفته می‌شود (احمدی و همکاران، ۱۳۹۳).

۲-۳-۲- ریسک

ریسک عبارت است از احتمال اختلاف بین بازده واقعی طرح و بازده مورد انتظار (مناجاتی و همکاران، ۱۳۹۶). معمولاً فرض بر این است که سرمایه‌گذاران از ریسک گریزان بوده و آن را دوست ندارند و همواره به دنبال آن

[۲] Dividend
[۳] Holding period return
[۴] Expected return
[۵] Realized return

هستند در دارایی‌هایی سرمایه‌گذاری کنند که دارای بیشترین بازده و کمترین ریسک باشند. به بیان دیگر، سرمایه‌گذاران همواره بازده سرمایه‌گذاری را به عنوان یک عامل مطلوب و ریسک یا واریانس بازده‌ها را به عنوان یک عامل نامطلوب در نظر می‌گیرند (بیات و اسدی، ۱۳۹۶).

ریسک را می‌توان به دو دسته تقسیم نمود: ریسک سیستماتیک و ریسک غیرسیستماتیک.

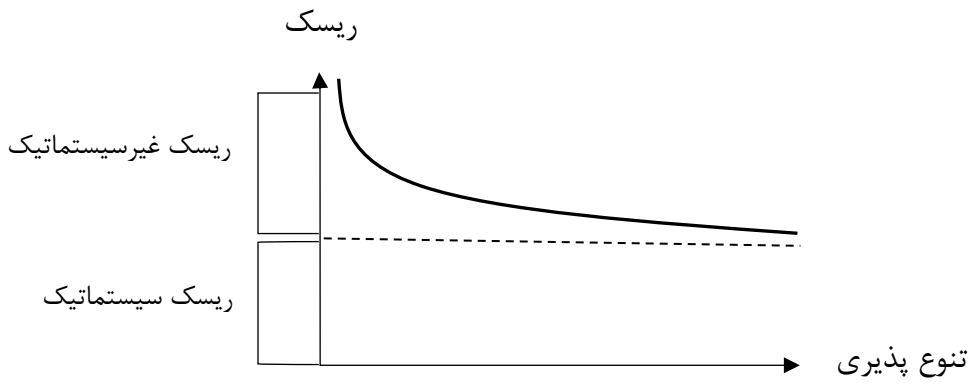

شکل ۲-۱- انواع ریسک پرتفوی

۲-۳-۲-۱- ریسک غیر سیستماتیک (کاهش پذیر یا قابل اجتناب)

ریسک غیر سیستماتیک، آن بخش از ریسک کل سهام است که بتوان از طریق تنوع بخشی (افزایش تنوع سهام) کاهش داد. در واقع این ریسک به یک شرکت یا صنعت خاص اختصاص دارد. برخی از عوامل ایجاد کننده این ریسک عبارتند از: خدمات و کالای‌های شرکت یا صنعت، اقدامات رقیبان، نوع مدیریت و ساختار هزینه شرکت. لذا این ریسک قابل کنترل می‌باشد.

۲-۳-۲-۲- ریسک سیستماتیک (کاهش ناپذیر یا غیر قابل اجتناب)

ریسک سیستماتیک، قسمتی از ریسک کل است که نتوان آن را با استفاده از تنوع بخشی کاهش داد. در واقع این ریسک از طریق عواملی به وجود می‌آید که قیمت کل سهام موجود را تحت تأثیر خود قرار می‌دهند. مانند چرخه‌های تجاری، تورم و بیکاری و تحولات سیاسی و اقتصادی. لذا این ریسک غیر قابل کنترل است.

با توجه به شکل ۲-۱، می‌توان مشاهده کرد که ریسک کل مجموعه با شیب ثابتی کاهش نمی‌یابد. هنگامی که سهام جدید اضافه می‌شوند، ریسک کل مجموعه با شیب بیشتری نزولی بوده و به تدریج از شدت شیب آن کاسته می‌شود. این روند کاهشی تا جایی ادامه می‌یابد که دیگر با تنوع بخشی ریسک کل کاهش پیدا نکند و تنها ریسک سیستماتیک به عنوان ریسک مجموعه بماند (مناجاتی و همکاران، ۱۳۹۶).

۲-۴- پرتفوی[۶]

پرتفوی به معنای سبد سرمایه‌گذاری است. سبد سرمایه‌گذاری مفهومی فراتر از سبد سهام است و شامل سرمایه‌گذاری‌های غیر سهم نیز می‌باشد. در حقیقت یک پرتفوی، در برگیرنده دارایی‌های مالی و حقیقی سرمایه‌گذار است که تشکیل آن با هدف کاهش ریسک صورت می‌گیرد (احمدی و همکاران، ۱۳۹۳).

۲-۴-۱- بهینه‌سازی پرتفوی[۷]

در نظریهٔ کلاسیک انتخاب سبد، اینگونه تصور شده است که با تشکیل پرتفوی از سهام صنایع مختلف، به عبارتی تنوع بخشی، می‌توان ریسک پرتفوی را کاهش داد این در حالی است که در نظریهٔ مدرن علاوه بر تنوع بخشی، روابط یا کوواریانس بین دارایی‌ها نیز در نظر گرفته می‌شود اما نه فقط برای مدیریت ریسک بلکه برای بدست‌آوردن بازده یکسان با ریسک کمتر نسبت به نظریه کلاسیک. از طرفی دیگر دانستن بازده و ریسک دقیق جهت سرمایه‌گذاری برای سرمایه‌گذار غیر ممکن است و مشکلی که سرمایه‌گذار با آن مواجه است ندانستن میزان وزن‌های سرمایه‌گذاری در هر کدام از سهام است. به این مسئله، مسئله انتخاب سبد گفته می‌شود

[۶] Portfolio
[۷] Portfolio Optimization

(گوکگاز و آتماکا[۸]، ۲۰۱۲). بنابراین برای حل این مسئله، مارکویتز (۱۹۵۲) مسئله انتخاب پرتفوی بهینه را از یک مجموعه سرمایه‌گذاری طرح کرد. هدف این مسئله این است که بتوان با مجموعه‌ای از دارایی‌های در دسترس، پرتفویی انتخاب گردد که علاوه بر کمینه‌سازی ریسک سبد، سطح حداقلی از بازده را نیز جهت سرمایه‌گذاری برآورد سازد (راعی و همکاران، ۱۴۰۰). این نظریه که ایده اصلی آن بر اساس این بود که بازده مورد انتظار به عنوان بازده سرمایه‌گذاری و واریانس بازده مورد انتظار به عنوان ریسک سبد سرمایه‌گذاری در نظر گرفته می‌شود، منشأ بروز تئوری نوین پرتفوی یا نظریه میانگین- واریانس[۹] قرار گرفت (ژیا و همکاران[۱۰]، ۲۰۰۰). در رویکرد سنتی تئوری پرتفوی، سرمایه‌گذار باید در اوراق بهادار با بیشترین بازده مورد انتظار سرمایه‌گذاری کند؛ اما مارکویتز چنین تصمیمی را غیر عقلانی دانست؛ چرا که سرمایه‌گذار باید دو مسئله بازده و ریسک را به صورت همزمان در نظر بگیرد، به عبارتی باید ضمن تلاش برای حداکثرسازی بازده مورد انتظار، در جستجوی به حداقل رساندن ریسک سرمایه‌گذاری‌ها نیز بود. از این رو، می‌توان گفت که هر سرمایه‌گذار، دو هدف متضاد و مخالف پیش رو دارد و می‌بایست بین آنان تعادل برقرار کند. لذا سرمایه‌گذار، سبد سرمایه‌گذاری را برای کاهش ریسک سرمایه‌گذاری‌های خود نگهداری می‌کند و تلاش دارد تا حد ممکن تنوع سبد سرمایه‌گذاری خود را بالا ببرد تا ریسک سرمایه‌گذاری‌های خود را کاهش دهد (فبوزی، نیو و ژو[۱۱]، ۲۰۱۲). بهینه‌سازی پرتفوی به معنی انتخاب بهترین ترکیب از دارایی‌های مالی است به گونه‌ای که بازده پرتفوی سرمایه‌گذاری حداکثر و ریسک آن حداقل گردد و هرچه ریسک پرتفوی بیشتر شود سرمایه‌گذار بازده بیشتری را انتظار خواهد داشت. هر یک از سرمایه‌گذاران بر اساس میزان ریسک‌پذیری و ریسک‌گریزی خود، نقطه‌ای را بر روی مرز کارا[۱۲] انتخاب می‌کند که بازده حداکثر و ریسک حداقل باشد. در شکل ۲-۲، منحنی رسم شده به معنای مرز کارا می‌باشد که ترکیب بهینه‌ای از ریسک و بازده می‌باشد. هر نقطه یک پرتفوی سرمایه‌گذاری‌ست

[۸] Gökgöz & Atmaca
[۹] Mean-Variance Theory
[۱۰] Xia et al.
[۱۱] Fabozzi, Neave and Zhou
[۱۲] Froniter efficient

که هر چه به مرزکارا نزدیک‌تر باشند، دارای بازده بالاتر و درجه ریسک کمتر می‌باشند (نصراصفهانی و همکاران[۱۳]، ۲۰۱۶).

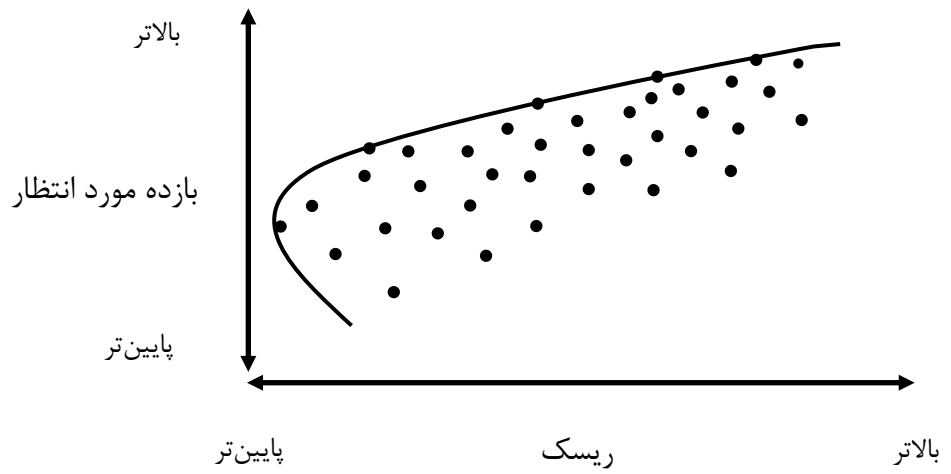

شکل ۲-۲- نمونه‌ای از مرز کارا مؤثر

حال برای بدست آوردن سبد سهام بهینه به روش ماکویتز که بر اساس حداقل واریانس به ازای سطح معینی از بازده است، مدل برنامه‌ریزی خطی زیر را خواهیم داشت:

$$min \sum_{i=1}^{N} \sum_{j=1}^{N} w_i w_j \sigma_{ij} \qquad (۳-۲)$$

$$Subject\ to \quad \sum_{i=1}^{N} w_i \mu_i = R^* \qquad (۴-۲)$$

$$\sum_{i=۱}^{N} w_i = ۱ \qquad (۵-۲)$$

$$۰ \leq w_i \leq ۱ \ , i = ۱, \dots, N \qquad (۶-۲)$$

[۱۳] Nasr Esfahani er al.

در روابط بالا داریم:

N : تعداد سهام موجود

w_i : وزن مربوط به سهم i ام در سبد سرمایه‌گذاری

μ_i : بازدهی سهم i ام

σ_{ij}: کوواریانس بین سهام، به عنوان معیار همراهی و حرکتی بین نرخ‌های بازدهی سهام مختلف

R^* : بازده مورد انتظار سبد سهام

در روابط بالا داده‌های ورودی، بازده و ماتریس واریانس-کوواریانس بازده مورد انتظار اوراق بهادار در یک پرتفوی می‌باشد. در مدل مذکور سرمایه‌گذار به‌دنبال حداکثرسازی مطلوبیت خویش در پایان دوره است. به عبارت دیگر، سرمایه‌گذار با در نظر داشتن دو عامل ریسک و بازده، تلاش می‌کند که ریسک خود را با بیشترین بازده حداکثر کند (مارکویتز، ۱۹۵۲).

۲-۴-۲- تنوع بخشی و بازده

حال ممکن است این سؤال پیش بیاید که افزایش تنوع چگونه بر ریسک و بازده پرتفوی و به عبارتی مرز کارا تأثیر خواهد داشت. برای درک و پاسخ به این سؤال یک حالت ساده یعنی وزن یکسان سهام موجود در سبد را مورد بررسی قرار می‌دهیم. ریسک سبد برابر است با:

$$\sigma_p = \frac{1}{n}\sqrt{\sum_{i=1}^{n}\sum_{j=1}^{n} Cov_{i,j}} \qquad (۷-۲)$$

همچنین بازده سبد به صورت زیر تعریف می‌شود:

(۸-۲)

$$E(R_p) = \frac{1}{n}\sum_{j=1}^{n} E(R_j)$$

برای سادگی هر چه بیشتر، واریانس و کوواریانس کلیه سهام موجود در سبد را یکسان و برابر $\bar{\sigma}^2$ و $\overline{Cov}$ فرض می‌کنیم. بر این اساس، واریانس پرتفوی برابر خواهد بود با:

$$\sigma_p^2 = \frac{1}{n}\bar{\sigma}^2 + \frac{n-1}{n}\overline{Cov} \qquad (۹-۲)$$

با افزایش تعداد سهام موجود در پرتفوی، جمله اول در رابطه ۲-۱۳ یعنی $\frac{1}{n}\bar{\sigma}^2$ به صفر و جمله دوم یعنی $\frac{n-1}{n}\overline{Cov}$ به میانگین کوواریانس میل می‌کند. لذا، با افزایش تعداد سهام واریانس سبد به میانگین کوواریانس نزدیک خواهد شد. برای درک بهتر می‌توان رابطه ۲-۱۳ را به بر حسب ضریب همبستگی بازنویسی نمود:

$$\sigma_p^2 = \sigma^2\left(\frac{1-\rho}{n} + \rho\right) \qquad (۱۰-۲)$$

طبق رابطه بالا با افزایش تعداد سهام جمله اول داخل پرانتز یعنی $\frac{1-\rho}{n}$ کوچک و کوچک‌تر می‌شود و در حالت حدی واریانس سبد به $\sigma^2\rho$ میل می‌کند. حال اگر ضریب همبستگی کمتر از یک باشد واریانس پرتفوی از واریانس تک تک سهام نیز کمتر خواهد بود و تنوع بخشی ریسک پرتفوی را کاهش می‌دهد (احمدی و همکاران، ۱۳۹۳).

۲-۵- یادگیری و انواع آن

مسئله یادگیری به معنی یافتن یک الگوی جامع برای توضیح و تشریح داده‌ها است. به عبارتی دیگر روشی‌ست که در آن الگوریتم‌ها به کمک حجم محدودی از داده‌های جمع‌آوری شده، توانایی آموزش و یادگیری پیدا می‌کنند (ندایی و نجفی، ۱۳۹۷). در ادامه به صورت خلاصه به انواع مسئله یادگیری پرداخته خواهد شد.

۲-۵-۱- یادگیری با نظارت[۱۴]

یادگیری با نظارت به معنی ساختن یک رابطه یا یک تابع بین داده‌های ورودی و داده‌های خروجی است که براساس وجود تعدادی داده صورت می‌گیرد. حال اگر فضای داده‌های خروجی غیرقابل شمارش باشد به مسئله رگرسیون[۱۵] یا پیش‌بینی[۱۶] نامگذاری می‌شود و در غیر این صورت به آن یک مسئله دسته‌بندی[۱۷] گفته می‌شود. در واقع در این روش از یادگیری، تعدادی داده‌های ورودی و خروجی به عنوان داده‌های آموزشی[۱۸] وجود دارند و تلاش این روش یافتن تابعی است که بهترین رابطه را بین داده‌های ورودی و خروجی توضیح دهد (ندایی و نجفی، ۱۳۹۷). به عبارتی یافتن تابع به صورت زیر تعریف می‌شود:

$$f(x): X \longrightarrow Y \qquad (۱۱-۲)$$

۲-۵-۲- یادگیری بدون نظارت[۱۹]

حوزه دیگری در کنار یادگیری با نظارت به نام یادگیری بدون نظارت وجود دارد که در طی آن داده‌های ورودی بدون خروجی بوده و هدف این نوع از یادگیری، یافتن ساختاری‌ست که داده‌های مشابه را از داده‌های نامشابه شناسایی و متمایز کند. به عبارت دیگر داده‌های ورودی به خوشه[۲۰]هایی تقسیم‌بندی شوند که حداکثر شباهت را در درون هر شاخه و حداقل شباهت را بین خوشه‌ها داشته باشند. این مدل از یادگیری توانایی آموزش و

---

[۱۴] Supervised Learning
[۱۵] Regression
[۱۶] Prediction
[۱۷] Classification
[۱۸] Train data
[۱۹] Unsupervised Learning
[۲۰] Cluster

سازماندهی اطلاعات را بدون ارائه حتی یک سیگنال خطا دارد چرا که به الگوریتم اجازه می‌دهد به دنبال الگوهایی باشد که قبلاً اشاره نشده است (ساسیا[۲۱]، ۲۰۱۳) (ندایی و نجفی، ۱۳۹۷).

۲-۶- ماشین بردار پشتیبان

نوع جدیدی از ماشین یادگیری، به نام ماشین بردار پشتیبان، به دلیل کاربردهای گسترده از شناسایی الگو تا تخمین رگرسیون مورد توجه بسیار بوده است. این موضوع با اشاره به خصوصیات بارز ماشین بردار پشتیبان از قبیل تعمیم‌پذیری بالا و نبود خطاهای محلی میسر بوده است. ماشین بردار پشتیبان به عنوان یک الگوریتم یادگیری هسته جدید در پیش‌بینی غیرخطی سری‌های زمانی موفق بوده است. ماشین بردار پشتیبان در اواخر دهۀ ۱۹۹۰ توسط فردی به نام وپنیک[۲۲] ارائه شد. هدف این الگوریتم کمینه کردن ریسک ساختاری[۲۳] است. به عبارتی این الگوریتم می‌کوشد حد بالایی از خطای تعمیم را که شامل مجموع خطاهای دوره آموزشی و فاصله اطمینان است مینیمم سازد. این اصل با اصل به حداقل رساندن ریسک تجربی[۲۴] که معمولاً تنها خطای آموزشی را حداقل می‌کند متفاوت است. در نتیجه بر اساس همین ویژگی منحصر به فرد است که ماشین بردار پشتیبان دارای عملکرد نسبتاً بهتری در مقایسه با شبکه‌های عصبی که مبتنی بر حداقل‌سازی ریسک تجربی هستند، می‌باشد (کائو و فرانسیس[۲۵]، ۲۰۰۳). فرآیند آموزش تابع تصمیم ماشین بردار پشتیبان برای شناسایی یک ابر صفحه جداساز در نظر گرفته می‌شود، که ابر صفحه مذکور حاشیه دسته‌بندی را ماکسیمم می‌سازد. بنابراین ابر صفحه بهینه ابر صفحه‌ای است که حاشیه بین کلاس‌ها را حداکثر می‌کند و ساده‌ترین آن، خطی است که

[۲۱] Sathya
[۲۲] Vapnik
[۲۳] Structural Risk Minimization (SRM)
[۲۴] Emprical Risk Minimization (ERM)
[۲۵] Cao & Francis

که دو مجموعه نمونه مثبت و منفی یا دو ویژگی[۲۶] را از یکدیگر جدا می‌کند، مشروط بر آن که این تقسیم‌بندی دارای حداکثر حاشیه[۲۷] نیز باشد (درک و همکاران[۲۸]، ۲۰۲۰) (فنگ و همکاران[۲۹]، ۲۰۰۵).

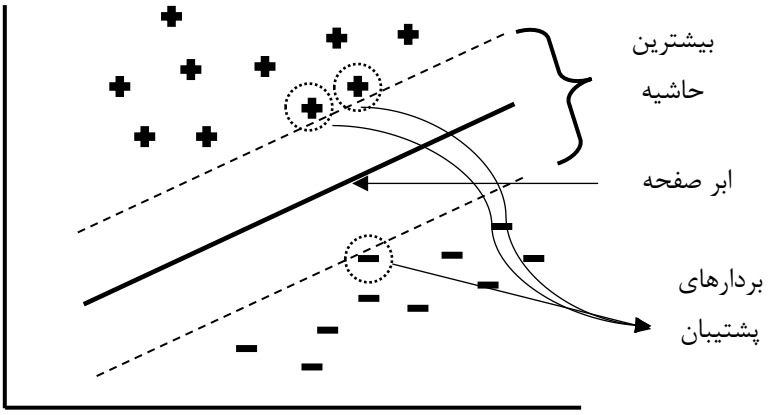

شکل ۲-۳- نمایی از ابرصفحه جداساز با در نظر گرفتن حداکثر حاشیه برای دو طبقه

در شکل بالا نمونه‌ای از داده‌های تفکیک پذیر(جدایی پذیر) دیده می‌شوند که با استفاده از یک ابر صفحه به صورت خطی به دو طبقه کاملاً متمایز تقسیم می‌شوند. این داده‌ها را می‌توان به صورت چندین خط (یا ابر صفحه در فضای n بعدی) تفکیک نمود و تمام این‌ها طبقه‌بندی‌های درستی می‌باشند. در اینجا سؤال این است که آیا بین ابرصفحه‌های جداساز تفاوتی وجود دارد و می‌توان یکی را به عنوان ابر صفحه جداساز بهینه انتخاب نمود؟ برای پاسخ به این سؤال باید به مفهوم ریسک پذیری دقت کرد. در واقع این سؤال به دنبال ابر صفحه‌ای است که بیشترین دقت را در تفکیک پذیری بتواند ارائه بدهد، به عبارتی با وجود جابجایی و وجود خطا، تفکیک

[۲۶] Feature
[۲۷] Maximum Margin
[۲۸] Derek et al.
[۲۹] Feng et al.

پذیری همچنان برقرار باشد. به عنوان مثال حالتی را در نظر بگیرید که هرکدام از ابرصفحه‌ها حاشیه‌ای از خطا را، دارا باشند.

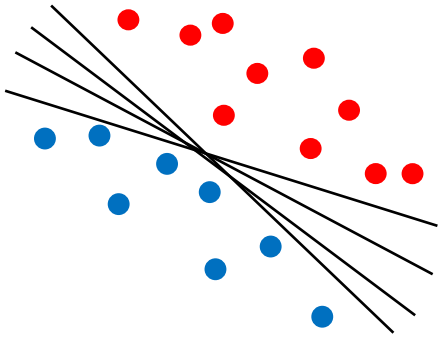

شکل ۲-۴- تفکیک داده‌ها در فضا توسط ابر صفحه‌های متفاوت

در شکل بالا اگر ابر صفحه‌ها به اندازه کافی از داده‌های هر طبقه دور نباشند، این امر باعث خواهد شد داده‌ها با اندکی جابجایی از ابر صفحهٔ جداساز عبور کنند و دقت دسته‌بندی کاهش یابد، در نتیجه ریسک تجربی افزایش می‌یابد.

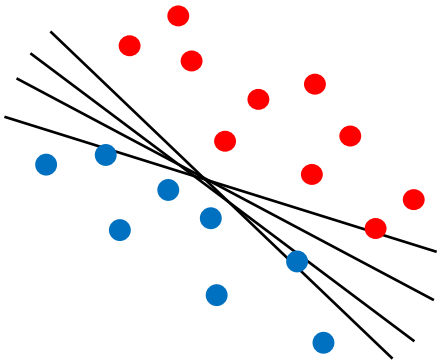

شکل ۲-۵- ابر صفحه‌ای که بیشترین فاصله را دارا می‌باشد، با جابجایی داده و کاهش دقت بهینه‌تر و مناسب‌تر بنظر می‌رسد.

همان‌طور که مشاهده می‌کنید ماشین بردار پشتیبان بر خلاف سایر روش‌های هوشمند از قبیل شبکه‌های عصبی[۳۰] (مینیمم‌سازی ریسک ساختاری[۳۱]) نه تنها به دنبال تفکیک‌کردن داده‌ها می‌باشد بلکه به دنبال تفکیک‌کننده‌ای است که بیشترین حاشیه ریسک را دارا باشد (فتاحی و کبودیان، ۲۰۱۵) (فنگ و همکاران، ۲۰۰۵). تفکیک‌کننده مذکور یا همان ابر صفحه، در ماشین بردار پشتیبان نقش تابع تصمیم[۳۲] را اجرا می‌کند که حاشیه دسته‌بندی[۳۳] را حداکثر می‌کند و این موضوع معادل این است که دقت دسته‌بندی حداکثر گردد. به فاصله نزدیکترین نقطه تا ابر صفحهٔ بهینه، حاشیه دسته‌بندی می‌گویند (ندایی و نجفی، ۱۳۹۷). در ادامه به دو مدل ماشین بردار پشتیبان، تفکیک پذیر خطی و تفکیک پذیر غیرخطی پرداخته خواهد شد. اگر بتوان داده‌های آموزشی را با استفاده از یک ابرصفحه بطور کامل از هم جدا نمود طوریکه از ماشین بردار پشتیبان با حاشیه سخت[۳۴]استفاده شود، به آن داده‌های تفکیک پذیر خطی گفته می‌شود و هدف این مدل از ماشین بردار پشتیبان یافتن ابرصفحه‌ای است که بیشترین فاصله را نسبت به نزدیکترین داده‌های هر کدام از طبقه‌ها برخوردار باشد و به این نزدیکترین داده‌ها بردارهای پشتیبان گفته می‌شود. در ماشین بردار پشتیبان با حاشیه سخت هیچ خطای آموزشی اجازه داده نمی‌شود و طبقه‌بندی اشتباه وجود ندارد و صفر است. اگرچه ممکن است این مدل دارای ساده‌ترین وکمترین هزینه محاسباتی باشد اما تفکیک پذیری خیلی از مشخصه‌ها به ندرت بدین شکل در عمل اتفاق می‌افتد (درک و همکاران، ۲۰۲۰). در این حالت فرض می‌گردد مجموعه‌ای از داده‌های آموزشی

[۳۰] Neural Network
[۳۱] Structural Risk Minimization (SRM)
[۳۲] Decision Function
[۳۳] Margin of Classification
[۳۴] Hard Margin

تفکیک پذیر به صورت زوج مرتب $\{x_i, y_i\}_{i=1}^{N}$ بیان می‌شوند که x_i متعلق به R^n و y_i دارای مقادیر $\{-1,+1\}$ می‌باشند.

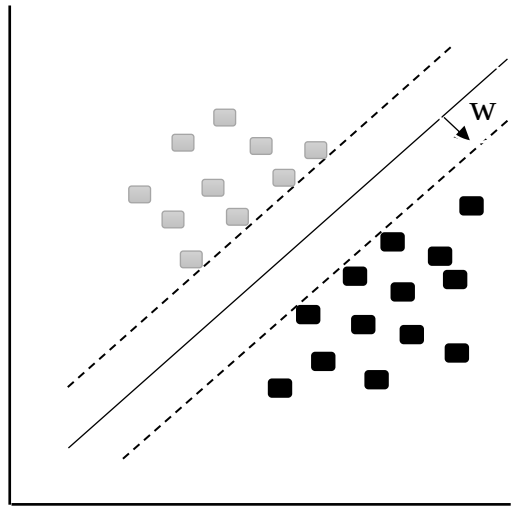

شکل ۲-۶- نمونه‌ای از ماشین بردار پشتیبان با حاشیه سخت، که هیچ خطای آموزشی ندارد.

با فرض اینکه وزن بردار عمود بر ابر صفحه یا شیب ابر صفحه برابر با w و عرض از مبدأ[۳۰] برابر با b باشد، هر خط جداکننده در فضای ۲ بعدی را با توجه به شکل ۲-۶ می‌توان به صورت معادله خط زیر نوشت:

$$w_1 x_1 + w_2 x_2 + b = 0 \qquad (۱۲-۲)$$

در حالت کلی و برای یک ابرصفحه خواهیم داشت:

$$\sum_i w_i x_i + b = 0 \qquad (۱۳-۲)$$

در واقع با فرض تفکیک‌پذیر بودن دو کلاس دادهٔ مثبت و منفی، بردارهای مرزی روی ابر صفحه‌های زیر قرار می‌گیرند:

$$\sum_i w_i x_i + b = \pm 1$$

(۱۴-۲)

با فرض تقسیم شدن فضا به دو دسته خواهیم داشت:

$$\begin{cases} w^T x_i + b \geq +۱ & \forall\, x_i \in Class1 \\ w^T x_i + b \leq -۱ & \forall\, x_i \in Class2 \end{cases} \qquad (۱۵\text{-}۲)$$

یا به عبارتی:

$$\begin{cases} w^T x_i + b \geq +۱ & for\ y = +1 \\ w^T x_i + b \leq -۱ & for\ y = -1 \end{cases} \qquad (۱۶\text{-}۲)$$

می‌توان رابطه ۲-۱۶ را به صورت زیر ترکیب کرد:

$$y_i(w^T x_i + b) - ۱ \geq ۰ \qquad (۱۷\text{-}۲)$$

ابر صفحه دسته‌بند در رابطه ۲-۱۳ به گونه‌ای یافت می‌شود که فاصله نزدیک‌ترین نقاط از ابر صفحه دسته‌بند برابر ۱ می‌باشد. همچنین فاصله نزدیکترین نقاط تا مبداء به صورت عمود بر روی نقاطی است که بر روی ابر صفحه $w^T x_i + b = +۱$ قرار دارند و به صورت زیر تعریف می‌شود:

$$\frac{|۱ - b|}{\|w\|} \qquad (۱۸\text{-}۲)$$

به طریق مشابه فاصله تا مبداء به صورت عمود برای نقاطی که بر روی $w^T x_i + b = -۱$ هستند به صورت زیر تعریف می‌شود:

$$\frac{|-۱ - b|}{\|w\|} \qquad (۱۹\text{-}۲)$$

با توجه به رابطه ۲-۱۹ فاصله مبدأ از ابر صفحه جداکننده به صورت زیر می‌باشد:

$$\frac{|b|}{\|w\|} \qquad (۲۰\text{-}۲)$$

با نظر به اینکه فاصله نزدیک‌ترین نقاط از ابر صفحه متعارف[۳۶] برابر یک واحد می‌باشد، لذا فاصله بردارهای پشتیبان یا همان نزدیکترین نقاط تا ابرصفحه جداساز را به کمک روابط بالا می‌توان به صورت زیر بیان نمود:

$$\frac{-۱}{\|w\|} \qquad \forall i \epsilon\ Class1 \tag{۲۱-۲}$$

$$\frac{۱}{\|w\|} \qquad \forall i \epsilon\ Class2 \tag{۲۲-۲}$$

$\|w\|$ همان نرم بردار w می‌باشد. با توجه به فاصله بردارهای پشتیبان تا ابر صفحه، حاشیه بین دو کلاس را از تفاضل دو عبارت فوق می‌توان محاسبه نمود. نکته دیگری که قابل ذکر است این است که در ماشین بردار پشتیبان تابع هدف به صورت حداکثر سازی حاشیه بین کلاس‌ها تعریف می‌گردد. بنابراین تابع هدف ماشین بردار پشتیبان به مطابق رابطه زیر خواهد بود.

$$\frac{۱}{\|w\|} - \frac{-۱}{\|w\|} = \frac{۲}{\|w\|} \tag{۲۳-۲}$$

لذا مدل نهایی ماشین بردار پشتیبان تفکیک پذیر خطی، بر اساس مدل بهینه‌سازی مقید زیر بدست می‌آید که در آن تابع هدف به صورت مینیمم‌سازی معکوس حاشیه و محدودیت‌ها به منظور جلوگیری از بروز خطا تعریف شده‌اند.

$$Min\ \frac{۱}{۲}\|w\|^{۲} \tag{۲۴-۲}$$

$$Subject\ to: y_i(w^T x_i + b) - ۱ \geq ۰ \tag{۲۵-۲}$$

ای تصمیم مدل بوده و آزاد در علامت تع

مسأله به صورت دوگان[۳۷] تعریف و حل شود. برای بدست آوردن شکل دوگان این مسئله، از تابع لاگرانژین[۳۸]

[۳۶] Canonical
[۳۷] Dual
[۳۸] Lagrangian function

استفاده می‌شود. بدین صورت که ضرایب لاگرانژ مثبت ($a_i \geq ۰$) رادر قیود ضرب کرده و از تابع هدف کسر می‌گردد. در نتیجه مدل ۲-۲۴ به صورت زیر تبدیل می‌شود که به آن مسئله اولیه[۳۹] گفته می‌شود:

$$\max_{a} \min_{w,b} L(w,b,a) \quad = \frac{۱}{۲}\|w\|^{۲} - \sum_{i=۱}^{m} a_i[y_i(w^T x_i + b) - ۱] \qquad (۲۶-۲)$$

در رابطه ۲-۲۶ مسئله اولیه به دنبال نقاطی است که از یک سو دارای حداقل جواب ممکن و از سوی دیگر دارای حداکثر جواب ممکن باشد، این نقاط به نقطه زینی[۴۰] معروف هستند. برای بدست آوردن نقاط زینی از شرایط Karush-Kuhn-Tucker (KKT) که نقشی اساسی در مسائل بهینه‌سازی مقید دارا می‌باشند، استفاده می‌گردد. این شرایط، شرایط لازم و کافی را برای یافتن پاسخ بهینه برای معادلات مقید بیان می‌کنند. به عبارتی باید مشتق تابع نسبت به متغیرهای w و b صفر باشد:

$$\frac{\partial}{\partial w} L_P = w - \sum_i a_i y_i x_i = ۰ \Rightarrow w = \sum_i a_i y_i x_i \qquad (۲۷-۲)$$

$$\frac{\partial}{\partial b} L_P = -\sum a_i y_i = ۰ \qquad a_i \geq ۰ \qquad (۲۸-۲)$$

مسئله SVM یک مسئله بهینه سازی محدب است که با استفاده از شرایط KKT می‌توان مسئله دوگان آن را بدست آورد:

$$Max(L_D) = \sum_i a_i - \frac{۱}{۲}\sum_i \sum_j a_i a_j y_i y_j x_i^T x_j \qquad (۲۹-۲)$$

$$\sum_i a_i y_i = ۰ \qquad a_i \geq ۰ \qquad (۳۰-۲)$$

L_D و L_P هر دو از یک شرایط بدست آمده‌اند، لذا با مینیمم سازی L_P یا ماکسیمم سازی L_D می‌توان به جواب رسید. به هر نمونه آموزشی یک ضریب لاگرانژ تعلق دارد و بردارهای پشتیبان به نمونه‌هایی گفته می‌شود که

[۳۹] Primal Problem
[۴۰] Saddle point

ضریب لاگرانژ آن‌ها بزرگتر از صفر باشد که به عبارتی معرف نمونه‌هایی هستند که بر روی ابر صفحات معادلات رابطه ۲-۱۵ قرار دارند.

حال اگر نتوان داده‌ها را با استفاده از یک ابر صفحه کلاس بندی نمود و به سادگی قابل تفکیک نباشند، داده‌ها به واقعیت نزدیک‌تر بوده و در این صورت برخی از محدودیت‌های رابطه ۲-۱۶ حل نشدنی باقی می‌مانند.

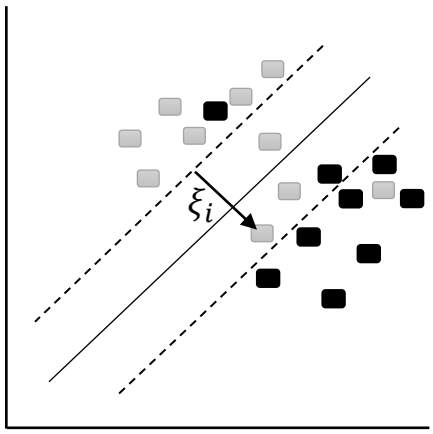

شکل ۲-۷- نمونه‌ای از ماشین بردار پشتیبان با تفکیک ناپذیر

برای گسترش ایده مطرح شده در بخش قبلی، متغیری تحت عنوان متغیر مثبت کاهشی یا کمبود[۴۱] در محدودیت‌های مسئله قبل تعریف می‌شود و خواهیم داشت:

$$\begin{cases} w^T x_i + b \geq +۱ - \xi_i \\ w^T x_i + b \leq -۱ + \xi_i \end{cases} \qquad \xi_i \geq ۰ \tag{۲-۳۱}$$

بابت هر خطایی که رخ می‌دهد، ξ_i که معیاری برای خطای طبقه‌بندی اشتباه می‌باشد، باید به صورت جداگانه افزایش یابد. این متغیر حتی الامکان باید برابر صفر باشد و به همین دلیل در تابع هدف به صورت حداقل‌سازی

[۴۱] Slack variable

$$Min\ \frac{۱}{۲}\|w\|^۲ + C\sum_{i=۱}^{m}\xi_i \tag{۲-۳۲}$$

به تابع هدف اضافه می‌شود تا در صورت امکان مقدار آن از صفر بیشتر نشود. در این وضعیت ماشین بردار پشتیبان با حاشیه نرم[۴۲] تعریف می‌شود.

$$y_i(w^T x_i + b) \geq ۱ - \xi_i \qquad (۳۳-۲)$$

$$\xi_i \geq ۰ \quad i = ۱, \dots, m$$

پارامتر C پارامتر جریمه[۴۳] نام دارد که توسط کاربر انتخاب می‌گردد. هر چه مقدار آن بزرگتر باشد به معنی اعمال جریمه بیشتر برای خطا است و خطای دسته‌بندی را کاهش اما زمان همگرایی الگوریتم را افزایش می‌دهد و بر عکس. همچنین متغیر ξ_i، میزان انحراف هر کدام از داده‌ها را با ابر صفحه تفکیک‌کننده مشخص می‌کند.

مسئله اولیه لاگرانژ مدل بالا برابر خواهد بود با:

$$\max_{a,\mu} \min_{w,b,\xi} L_P(w, b, a, \mu, \xi) = \frac{۱}{۲}\|w\|^۲ \qquad (۳۴-۲)$$
$$+C\sum_{i=۱}^{m} \xi_i^۲ - \sum_{i=۱}^{m} a_i[y_i(w^T x_i + b) - ۱ + \xi_i] - \sum_{i=۱}^{m} \mu_i \xi_i$$

با اعمال شرایط KKT خواهیم داشت:

$$\frac{\partial}{\partial w} L_P = w - \sum_i a_i y_i x_i = ۰ \Rightarrow w = \sum_i a_i y_i x_i \qquad (۳۵-۲)$$

$$\frac{\partial}{\partial b} L_P = -\sum_i a_i y_i = ۰ \qquad (۳۶-۲)$$

$$\frac{\partial}{\partial \xi_i} L_P = C - a_i - \mu_i = ۰ \qquad (۳۷-۲)$$

با محاسبه دوگان روابط، مسئله دوگان ماشین بردار پشتیبان حاشیه نرم برای رابطه ۲-۳۲ بدست می‌آید.

[۴۲] Soft Margin
[۴۳] Penalty Parameter

$$\max_{a_i}(L_D) = \sum_i a_i - \frac{۱}{۲}\sum_i\sum_j a_i a_j y_i y_j x_i^T x_j \qquad (۳۸-۲)$$

$$\sum_i a_i y_i = ۰ , ۰ \le a_i \le C \qquad (۳۹-۲)$$

همان طور که مشاهده می‌شود بین ماشین بردار پشیبان با حاشیه سخت و نرم، تنها یک تفاوت وجود دارد و آن هم کران متغیر a_i است. ابرصفحه جداکننده به گونه‌ای یافت می‌شود که حاشیه بین کلاس‌ها را حداکثر سازد و توانایی طبقه‌بندی داده‌های جدید را با دقت بالایی برخوردار باشد. در حالتی که داده‌ها به راحتی تفکیک‌پذیر نباشند، این ابر صفحه دقت کافی را دارا نبوده و در این صورت لازم می‌باشد داده‌ها در فضای دیگری که فضای مشخصه‌ها[۴۴] (ویژگی‌ها) نامیده می‌شود، نگاشت شوند. به گونه‌ای بتوان داده‌ها را در فضایی جدید به صورت خطی تفکیک نمود.

$$\Phi: R^d \to \mathcal{H} \qquad (۴۰-۲)$$

طبق رابطه ۲-۴۰ ابتدا داده‌ها به فضای اقلیدسی با ابعاد بالاتر نگاشت می‌شوند و سپس از ضرب داخلی عناصر بدست آمده استفاده می‌شود. در واقع از حاصضرب داخلی داده‌های ورودی در بردارهای پشتیبان برای تشکیل جداکننده خطی به شکل ابر صفحه استفاده می‌شود. بنابراین الگوریتم آموزش وابسته به این ضرب داخلی در فضای ویژگی می‌باشد. تابع کرنل[۴۵] به صورت زیر تعریف می‌شود.

$$K(x_i, x_j) = \phi(x_i).\phi(x_j) \qquad (۴۱-۲)$$

استفاده از توابع کرنل به ما این امکان را می‌دهد یک بسازیم که متناظر با یک رگرسیون غیرخطی در فضای ورودی است. توابع کرنل در واقع راهی است برای مقابله با مشکلاتی که دراکر و همکاران (۱۹۹۶) با آن رو به رو بودند. به عبارتی در تابع رگرسیونی که در فضای ویژگی

[۴۴] Future Space
[۴۵] Kernel

ساخته می‌شود اگر محاسبات در همین فضا انجام شوند باعث به وجود آمدن تعداد زیادی پارامترهای غیر بدیهی می‌گردد در حالی‌که با توابع کرنل این محاسبات در فضای خطی صورت می‌پذیرد، به این فرآیند ترفند کرنل[۴۶] می‌گویند (ساندرس و همکاران، ۲۰۱۲). مدل ۲-۳۲ به صورت زیر مدل می‌گردد:

$$Min\ \frac{۱}{۲}\|w\|^{۲} + C\sum_{i=۱}^{m}\xi_i \qquad (۴۲-۲)$$

$$y_i(w^T\phi(x_i) + b) \geq ۱ - \xi_i \qquad (۴۳-۲)$$

$$\xi_i \geq ۰ \quad i = ۱, \dots, m$$

مسئله دوگان در رابطه با ۲-۴۲ بر اساس نگاشت به صورت زیر مدل می‌شود:

$$\max_{a_i}(L_D) = \sum_i a_i - \frac{۱}{۲}\sum_i\sum_j a_i a_j y_i y_j K\left(x_i^T x_j\right) \qquad (۴۴-۲)$$

$$\sum_i a_i y_i = ۰ \quad , \quad ۰ \leq a_i \leq C \qquad (۴۵-۲)$$

با این نگاشت فرم غیرخطی ماشین بردار پشتیبان با استفاده از توابع کرنل[۴۷]تعریف می‌شود. در واقع به ترکیب تابع کرنل و ماشین بردار پشتیبان خطی، ماشین بردار پشتیبان غیرخطی گفته می‌شود.

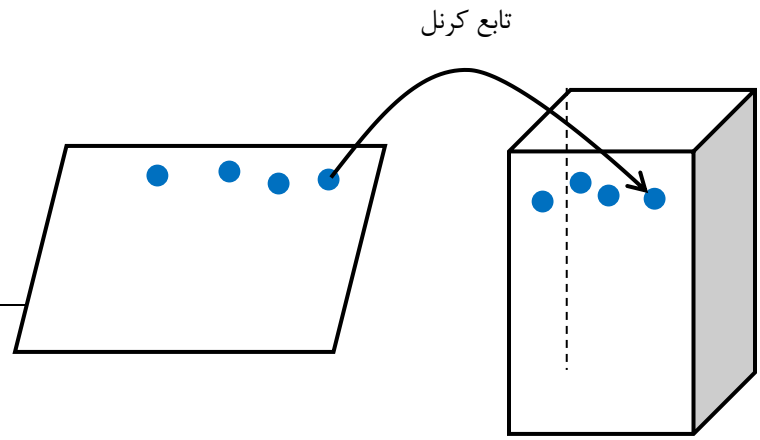

[۴۶] Kernel Trick
[۴۷] Kernel

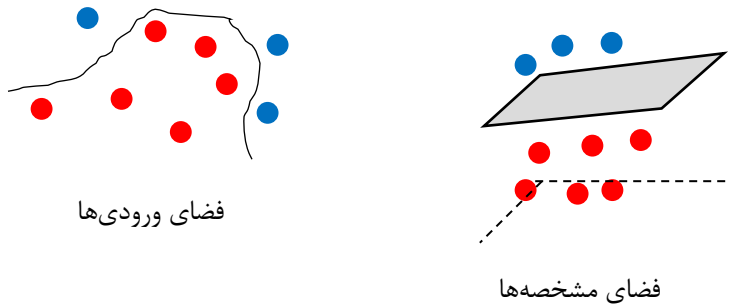

شکل ۲-۸- ماشین بردار پشتیبان غیرخطی

در اینجا می‌توان به تعدادی توابع کنترل که برای انجام نگاشت‌های غیرخطی توسعه یافته‌اند، اشاره نمود:

۱) تابع کرنل چند جمله‌ای[۴۸]:

$$\kappa(x_i, x) = (\gamma x^T x_i + r)^P \qquad (۴۶-۲)$$

۲) تابع کرنل RBF (گوسین[۴۹]):

$$\kappa(x_i, x) = exp(-\gamma \|x - x_i\|^۲) \qquad (۴۷-۲)$$

۳) تابع کرنل سیگموئید[۵۰]:

$$\kappa(x_i, x) = tanh(\gamma x^T x_i + r) \qquad (۴۹-۲)$$

[۴۸] Polymonial kernel
[۴۹] Radial Basis Function (Gaussian) kernel
[۵۰] Sigmoid kernel

۲-۷- رگرسیون بردار پشتیبان[۵۱]

مسئله رگرسیون بردار پشتیبان تعمیمی از مسئله دسته‌بندی می‌باشد. خروجی مسئله دسته‌بندی به صورت گسسته و متناهی است این در حالی است که خروجی رگرسیون بردار پشتیبان به صورت پیوسته تعریف می‌شود. به عبارت دیگر رگرسیون بردار پشتیبان یک تابع چند متغیره پیوسته تخمین می‌زند. ماشین‌های بردار پشتیبان، مسائل طبقه‌بندی دوتایی را با فرموله کردن آن‌ها به صورت بهینه‌سازی محدب حل می‌کنند (وپنیک، ۱۹۹۸). این مسائل بهینه‌سازی مستلزم یافتن حداکثر حاشیه ابر صفحه جداساز می‌باشند. این ابر صفحه‌ها نیز به کمک بردارهای پشتیبان شناسایی می‌گردند.

تعمیم‌پذیری بالا موجب توسعه و معرفی رگرسیون بردار پشتیبان گردیده است. تعمیم SVM به SVR با معرفی یک محدوده غیر حساس خطا[۵۲] در اطراف تابع که لوله یا مجرا خطا[۵۳] نامیده می‌شود، موفق بوده است. در این مدل هدف از بهینه‌سازی، یافتن لوله‌ای است که بهترین تخمین را از تابع پیوسته با در نظر گرفتن مقدار خطا و پیچیدگی مدل داشته باشد. در واقع SVR به صورت یک تابع محدب غیرحساس به خطا به عنوان مدل بهینه سازی تعریف می‌گردد و به دنبال باریک‌ترین لوله منحصر به فرد است که تعداد زیادی نمونه‌های آموزشی را در بر بگیرد. همانطور که در SVM ابر صفحه بهینه بر حسب بردارهای پشتیبان بدست می‌آید در SVR نیز مجرای بهینه بر حسب بردارهای پشتیبان برآورد می‌گردد (اوارد و خانا[۵۴]، ۲۰۱۵). ایدهٔ اصلی رگرسیون بردار پشتیبان، نگاشت داده‌ها در فضایی با ابعاد بالا از طریق نگاشت غیرخطی Φ و سپس رسم رگرسیون خطی در فضای ویژگی می‌باشد.

$$f(x) = w.\Phi(x) + b \tag{۲-۴۸}$$

[۵۱] Support Vector Regression (SVR)
[۵۲] ε-insensitive region
[۵۳] ε-tube
[۵۴] Award & Khanna

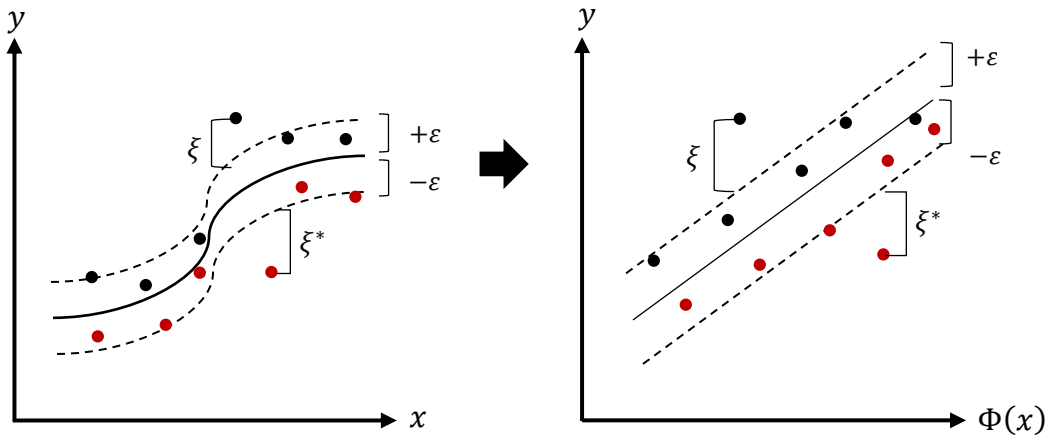

شکل ۲-۹- رگرسیون بردار پشتیبان

رگرسیون بردار پشتیبان مسئله برآورد تابع را به صورت یک مسئله بهینه‌سازی طراحی می‌کند طوری‌که سعی در یافتن باریک‌ترین لوله و حداقل‌سازی خطای پیش‌بینی دارد. به فاصله بین خروجی‌های پیش‌بینی شده و خروجی‌های موردنظر، خطای پیش‌بینی می‌گویند. این مدل به صورت زیر تعریف می‌گردد:

$$\min_{w,b} \frac{۱}{۲} \|w\|^۲ \tag{۴۹-۲}$$

$$s.t \ \ \Big(\big(w.\Phi(x_i)\big) + b\Big) - y_i \leq \varepsilon, i = ۱,۲,\dots,l \tag{۵۰-۲}$$

$$y_i - \Big(\big(w.\Phi(x_i)\big) + b\Big) \leq \varepsilon, i = ۱,۲,\dots,l \tag{۵۱-۲}$$

$$w \in R^n, b \in R$$

فرض ضمنی مسئله بهینه سازی بالا به این صورت است که نمونه‌های آزمایشی می‌توانند با دقت به وسیله تابع خطی در فضای ویژگی تقریب زده شوند. اگرچه در عمل، همیشه نویزها و عدم دقت‌هایی وجود دارد، بنابراین درک این مدل ایده آل دشوار خواهد بود. برای بهبود عملکرد این مدل رگرسیون حاشیه نرم مدل می‌گردد:

$$\min_{w,b,\xi_i,\xi_i^*} \frac{۱}{۲} \|w\|^۲ + C \sum_{i=۱}^{l} (\xi_i + \xi_i^*) \tag{۵۲-۲}$$

$$s.t\ \left(\left(w.\Phi(x_i)\right)+b\right)-y_i \le \varepsilon+\xi_i, i=۱,۲,\dots,l \qquad (۵۳-۲)$$

$$y_i-\left(\left(w.\Phi(x_i)\right)+b\right) \le \varepsilon+\xi_i^*, i=۱,۲,\dots,l\xi_i \ge ۰, i=۱,۲,\dots,l \qquad (۵۴-۲)$$

$$\xi_i^{(*)} \ge ۰, i=۱,۲,\dots,l \qquad (۵۵-۲)$$

ξ_i و ξ_i^* متغیرهای کمبود هستند و C متغیری است که به صورت دستی تنظیم می‌شود و رابطه‌ای بین یکنواختی و مقدار خطا برقرار می‌کند. هر چه مقدار C افزایش یابد مسئله وزن بیشتری به حداقل‌سازی مقدار خطا پیش‌بینی می‌دهد و به ماشین بردار با حاشیه سخت نزدیکتر می‌شود، در نتیجه حاشیه بین طبقات کاهش می‌یابد و هر چه C کمتر باشد، مسئله وزن بیش‌تری را به حداکثرسازی حاشیه بین طبقات می‌دهد (لین و همکاران[۵۵]، ۲۰۰۷).

با اعمال شرایط KKT (برابر صفر قرار دادن حاصلضرب قیود در ضرایب لاگرانژ) مسئله دوگان مدل بالا بر اساس نگاشت به صورت زیر مدل می‌شود:

$$\max_{a,a^*} -\frac{۱}{۲}\sum_{ij}(a_i-a_i^*)\left(a_j-a_j^*\right)\Phi(x_i)'\Phi(x_i)-\varepsilon\sum_i(a_i-a_i^*)+y_i\sum_i(a_i-a_i^*) \qquad (۵۶-۲)$$

$$\sum_i(a_i-a_i^*)=۰, a, a^*\epsilon[۰,C] \qquad (۵۷-۲)$$

$$K(x_i,x)=\phi(x_i).\phi(x) \qquad (۵۸-۲)$$

$$w=\sum_{i=1}^{l}(a_i-a_i^*)\phi(x_i) \qquad (۵۹-۲)$$

$$f(x)=\sum_{i=1}^{l}(a_i-a_i^*)\ K(x_i,x)+b \qquad (۶۰-۲)$$

[۵۵] Lin et al.

a, a^* ضرایب لاگرانژ بوده و دارای مقداری غیرصفر و برابر C در خارج از مرز لوله هستند و همزمان نمی‌توانند غیر صفر باشند؛ چرا که بدین معنی است یک داده آموزشی هم در مرز بالایی و هم در مرز پایینی قرار دارد که غیرممکن است. بردارهای پشتیبان دارای $a, a^* \epsilon (۰, C)$ می‌باشند.

۲-۶- مروری بر ادبیات موضوع

در این بخش پژوهش‌ها و تحقیقات پیشین در عرصهٔ بهینه‌سازی و انتخاب سبد سهام مبتنی بر پیش‌بینی مورد بررسی قرار گرفته است. پژوهش‌هایی در ارتباط با بهینه‌سازی سبد سرمایه مبتنی بر پیش‌بینی صورت گرفته است که در آنان از انواع ابزارها به منظور پیش‌بینی استفاده شده است. فریتاس و همکاران (۲۰۰۹)، با استفاده از شبکه عصبی، برای ارزیابی نرمال بودن خطای‌های پبش‌بینی، به پیش‌بینی بازده قیمت ۸۲ سهام شاخص بورس برزیل و بهینه‌سازی انتخاب سهام پرداختند. نتایج آن‌ها نشان داد که دستیابی به خطاهای پیش‌بینی نرمال با سری‌های زمانی غیر نرمال امکان پذیر است. همچنین در مقایسه با مدل میانگین_ واریانس مارکویتز، ابزار مذکور بازده بالاتری با ریسک یکسان را به عمل می‌آورد.

پینتو و همکاران[۵۶] (۲۰۱۱) در پژوهش خود با پیش‌بینی بازده و ریسک به بررسی تنوع سهام و کاهش ریسک با استفاده مدل مارکویتز پرداختند. آن‌ها در مدل پیش‌بینی خود از خود رگرسیونی برون‌زا[۵۷] استفاده کردند و پس از آن به تعیین اوزان بهینه پرداختند. نتایج آن‌ها نشان داد که این رویکرد در پیش‌بینی بازده و ریسک سهام موفق بوده و تنوع در سرمایه‌گذاری ریسک سهام نیز کاهش می‌یابد. آن‌ها مسئله خود را بر روی شاخص بورس برزیل انجام دادند.

[۵۶] Pinto et al.
[۵۷] Autoregressive exogenous (ATX)

هائو و همکاران[۵۸] (۲۰۱۳) در پژوهش خود، مسئله بهینه سازی سبد سهام مبتنی بر پیش‌بینی را در نظر گرفتند که پیش‌بینی از طریق رگرسیون بردار پشتیبان و شبکه عصبی صورت گرفته است به گونه‌ای که خطای پیش‌بینی به عنوان ریسک حداقل گردد. برای آزمایش این مسئله مجموعه‌ای از سهام شاخص شانگهای را بکار گرفتند و نتایج آن‌ها نشان داد که بهینه‌سازی سبد سهام مبتنی بر پیش‌بینی با استفاده از رگرسیون بردار پشتیبان علاوه بر آن که دارای خطای پیش‌بینی کمتری است، دارای بازده بالاتری با ریسک یکسان نسبت به روش بهینه‌سازی سبد سهام مبتنی بر پیش‌بینی با استفاده از شبکه عصبی می‌باشد و روش اول نسبت به روش دوم برتری دارد.

میشرا و همکاران[۵۹] در سال ۲۰۱۶ یک مدل میانگین_ واریانس مبتنی بر پیش‌بینی به منظور حل مسائل بهینه‌سازی سبد مقید ارائه دادند. آنان در پژوهش خود ابتدا از شبکه‌های عصبی به منظور پیش‌بینی بازده استفاده می‌کنند و در رابطه با بهینه‌سازی سبد از الگوریتم‌های خود تکاملی چند هدفه به خصوص الگوریتم هوش ازدحامی بهره می‌برند. نتایج آنان نشان داد که بهینه‌سازی سبد با استفاده از الگوریتم ازدحام ذرات و مبتنی بر پیش‌بینی بازده دارای عملکرد بهتری نسبت به مدل مارکویتز و دیگر الگوریتم‌های بهینه سازی می‌باشد.

یانگ و همکاران[۶۰] در سال ۲۰۱۹ اذعان داشتند که موفقیت در انتخاب سهام مشروط بر عملکرد آتی بازار سهام است. آنان برای این ادعای خود به پیش‌بینی قیمت سهام چین پرداختند که مرحله اول شامل پیش‌بینی قیمت سهام با استفاده از روش محاسباتی هوشمند از قبیل یادگیری ماشین با قدرت یادگیری بالا و محاسبات سریع

[۵۸] Hao et al.
[۶۰] Mishra et al.
[۶۰] Yang et al.

و مرحله دوم شامل یک ترکیب خطی از داده‌های پیش‌بینی شده و داده‌های بنیادین می‌باشد. نتایج این محققان نشان می‌دهد عملکرد این روش نسبت به مدل‌های سنتی بدون پیش‌بینی بهتر می‌باشد.

چن و همکاران[۶۱] در سال ۲۰۲۱ به بهینه‌سازی سبد سهام مبتنی بر پیش‌بینی با استفاده از یادگیری ماشین بر روی سهام شانگهای پرداختند. در این پژوهش در مرحله اول ، یک مدل هیبریدی[۶۲] و الگوریتم کرم شب تاب بهبود یافته[۶۳] برای پیش بینی قیمت سهام برای دوره بعدی پیشنهاد شده است. به عبارتی پارامترهای مدل هیبریدی توسط الگوریتم کرم شب تاب بهبود یافته برآورد شده و سپس در مرحله دوم با استفاده از نظریه میانگین_ واریانس به بهینه‌سازی سبد سهام به کمک داده‌های پیش‌بینی شده، پرداخته شده است. نتایج این پژوهش نشان می‌دهد که روش پیشنهادی دارای عملکرد بهتری نسبت به روش‌های کلاسیک بدون در نظر گرفتن پیش‌بینی می‌باشد.

ما و همکاران[۶۴] در سال ۲۰۲۱ به منظور پیش‌بینی، از الگوریتم‌های یادگیری ماشین و یادگیری عمیق و به منظور بهینه‌سازی، از تئوری میانگین_ واریانس و امگا بهره جستند. آنان در یادگیری ماشین از رگرسیون بردار پشتیبان و جنگل تصادفی[۶۵] و در یادگیری عمیق از روش‌های DMLP[۶۶]، LSTM[۶۷] و CNN[۶۸] استفاده نمودند و نتایج آنان نشان داد که بهینه‌سازی سبد به کمک تئوری میانگین_ واریانس و پیش‌بینی بر اساس الگوریتم جنگل تصادفی دارای عملکرد بهتری می‌باشد.

---

[۶۱] Chen et al.
[۶۲] eXtreme Gradient Boosting (XGBoost)
[۶۳] improved firefly algorithm (IFA)
[۶۴] Ma et al.
[۶۵] Random forest
[۶۶] Deep multilayer perceptron
[۶۷] Long short-term memory
[۶۸] Convolutional neural network

پراکندگی جغرافیایی پژوهش‌های منتخب انجام شده در بازه‌ی سال‌های ۲۰۰۹ تا ۲۰۲۱ که شامل ۲۴ نویسنده مختلف است، مطابق نمودار شکل ۲-۹ می‌باشد. همانطور که در این نمودار مشخص است، کشور چین، بیشترین سهم را در این پژوهش‌ها دارد.

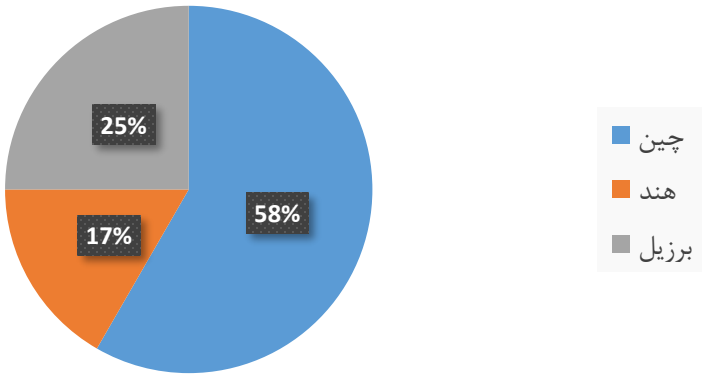

شکل ۲-۱۰- نمودار پراکندگی مطالعات بهینه سازی سبد سرمایه‌گذاری

لازم به ذکر می‌باشد که در مجلات علمی_داخلی نیز پژوهش‌هایی در این زمینه صورت گرفته است. برای مثال زمانی و همکاران در سال ۱۳۹۳ پژوهشی در این زمینه انجام دادند. آنان شبکه عصبی فازی را در زمینه پیش‌بینی بکار بردند و در ادامه مدل‌های ریاضی بهینه سازی، بر اساس فاکتورهایی مانند میانگین، واریانس و چولگی سبد پرتفوی ارائه می‌گردد. در انتها برای حل این مدل‌ها از الگوریتم ژنتیک استفاده شده است. نتایج پژوهش آنان نشان می‌دهد که مدل‌های ارائه شده در مقایسه با روش‌های سنتی، بازده بیشتری را برای سرمایه‌گذار به ارمغان می‌آورد. در سال ۱۳۹۹ خواجه‌زاده و همکاران از طریق الگوریتم رگرسیون لبه به پیش‌بینی بازده سهام پرداختند. در ادامه با روش مارکوف و الگوریتم خوشه‌بندی طیفی فیلتر لازم به منظور انتخاب داده‌های اولیه مناسب صورت می‌گیرد. ایشان سرانجام بهینه سازی سبد سهام را با استفاده از روش فراابتکاری فرهنگی انجام دادند. نتایج پژوهش آنان نشان می‌دهد مدل پیشنهادی آنان با توجه به معیار شارپ دارای عملکرد بهتری می‌باشد. در مقالات مذکور، روش‌های متعددی به منظور بهینه سازی سبد سهام معرفی شدند که به منظور تحلیل و بررسی بهتر، به طور خلاصه، می‌توان آنان را در قالب جداول زیر نشان داد.

جدول ۲-۱- خلاصه‌ای از مقالات منتخب خارجی

ردیف	نویسنده	سال	روش پیش‌بینی	روش بهینه‌سازی
۱	Freitas et al.	۲۰۰۹	شبکه‌های عصبی	مینیمم‌سازی ریسک سیستماتیک
۲	Pinto et al.	۲۰۱۱	خود رگرسیونی برون‌زا	مدل مارکویتز
۳	Hao et al.	۲۰۱۳	رگرسیون بردار پشتیبان و شبکه‌های عصبی	مینیمم‌سازی ریسک سیستماتیک
۴	Mishra et al.	۲۰۱۶	شبکه‌های عصبی	الگوریتم ازدحام ذرات
۵	Yang et al.	۲۰۱۹	یادگیری ماشین	ترکیبی خطی از داده‌های پیش‌بینی شده و متغیرهای بنیادین
۶	Chen et al.	۲۰۲۱	مدل هیبریدی و الگوریتم کرم شب تاب بهبود یافته	مدل مارکویتز
۷	Ma et al.	۲۰۲۱	رگرسیون بردار پشتیبان و جنگل تصادفی و یادگیری عمیق از روش‌های DMLP، LSTM و CNN	مدل مارکویتز

جدول ۲-۲- خلاصه‌ای از مقالات منتخب داخلی

ردیف	نویسنده	سال	روش پیش‌بینی	روش بهینه‌سازی
۸	زمانی و همکاران	۱۳۹۳	شبکه‌های عصبی فازی	الگوریتم ژنتیک
۹	خواجه‌زاده	۱۳۹۹	الگوریتم رگرسیون لبه	الگوریتم فراابتکاری فرهنگی

با توجه به ادبیات پژوهش می‌توان پی برد که تاکنون در زمینه انتخاب بهینه سبد سهام مبتنی بر پیش‌بینی قیمت سهام به کمک رگرسیون بردار پشتیبان خروجی چندگانه تحقیقی صورت نگرفته است و از آن می‌توان به عنوان یک خلأ تحقیقاتی نام برد. بر همین اساس پژوهش جاری از ابزار مذکور در زمینه پیش‌بینی قیمت سهام استفاده می‌نماید و در انتها به بهینه‌سازی پرتفوی می‌پردازد.

۲-۷- جمع‌بندی

در این فصل سعی گردید به معرفی و بررسی مفاهیم اصلی در حوزه انتخاب سبد سرمایه‌گذاری بهینه و ابزار پیش‌بینی یعنی رگرسیون بردار پشتیبان رسیدگی گردد و در آخر نیز ادبیات موضوع و برخی از مطالعاتی که در این حوزه انجام گرفته بود شرح داده شد. می‌توان پی برد که تاکنون در این زمینه، پژوهش‌های اندکی صورت گرفته و با توجه به اهمیت موضوع، پتانسیل زیادی برای پرداختن به این ضمیمه وجود دارد. در فصل بعد به معرفی مدل مورد بررسی در این پژوهش و نحوه بکارگیری آن پرداخته خواهد شد.

فصل سوم

روش شناسی تحقیق

۳-۱- مقدمه

در هر پژوهشی روش مناسبی بر اساس موضوع تحقیق برای انجام آن در نظر گرفته می‌شود. این روش شامل مجموعه‌ای از قواعد، ابزار و راه حل‌های معتبر، قابل اعتماد و سازمان یافته برای دستیابی به راه حل مشکلات و بررسی واقعیت‌ها است. در این فصل به معرفی مدل مورد نظر و الگوریتم مربوطه که برای حل نمودن مدل مسئله بکار برده می‌شود، پرداخته خواهد شد. همچنین متغیرهای مورد بررسی، داده‌ها و اطلاعات جمع آوری شده و بازه زمانی تحقیق برای حل مسئله تعریف خواهند گردید.

۳-۲- روش تحقیق

این پژوهش یک پژوهش کاربردی بوده و مبتنی بر پژوهش‌های میدانی می‌باشد؛ به عبارتی براساس اطلاعات گردآوری شده از بازار S&P۵۰۰، فرضیه پژوهش و در انتها نتایج حاصل به تمام جامعه آماری بسط داده می‌شود. همان طور که قبلاً نیز ذکر شد، انتخاب صحیح جهت سرمایه‌گذاری و تشکیل سبد منوط به پیش‌بینی با دقت بالا می‌باشد، که یکی از روش‌های پیش‌بینی استفاده از مدل‌های غیرخطی از قبیل رگرسیون بردار پشتیبان است. تحقیقات پیشین نشان می‌دهند که این مدل دارای دقت پیش‌بینی بالایی می‌باشد. در این پژوهش فرض بر آن است که می‌توان این دقت پیش‌بینی را بالاتر برد و عملکرد پرتفوی را

بهبود بخشید. لذا در این پژوهش از مدل توسعه یافته آن یعنی رگرسیون بردار پشتیبان با خروجی چندگانه به منظور پیش‌بینی استفاده می‌گردد. این امر می‌تواند منجر به انتخاب سبد سهام با عملکرد بهتری گردد. برای تحقق این موضوع، پیش‌بینی بازده قیمت سهام با استفاده از مدل رگرسیون بردار پشتیبان با خروجی چندگانه به صورت همزمان و رگرسیون بردار پشتیبان یکتا انجام می‌شود و دقت پیش‌بینی دو روش محاسبه می‌گردد تا به این نتیجه برسیم آیا مدل پیشنهادی دارای دقت پیش‌بینی بالاتری خواهد بود یا خیر. در ادامه با استفاده از داده‌های پیش‌بینی شده به تشکیل پرتفوی و به مقایسه عملکرد پرتفوی حاصل از داده‌های پیش‌بینی شده، می‌پردازیم. در واقع این پژوهش شامل دو مرحله می‌باشد، مرحله اول، پیش‌بینی با استفاده از رگرسیون بردار پشتیبان چندگانه و مرحله دوم شامل استفاده از داده‌های پیش‌بینی به منظور بهینه‌سازی سبد سهام با درنظر گرفتن ریسک سیستماتیک به جای ریسک کل. به طور کلی هدف تحقیق دسترسی به پاسخ‌های پرسش تحقیق می‌باشد.

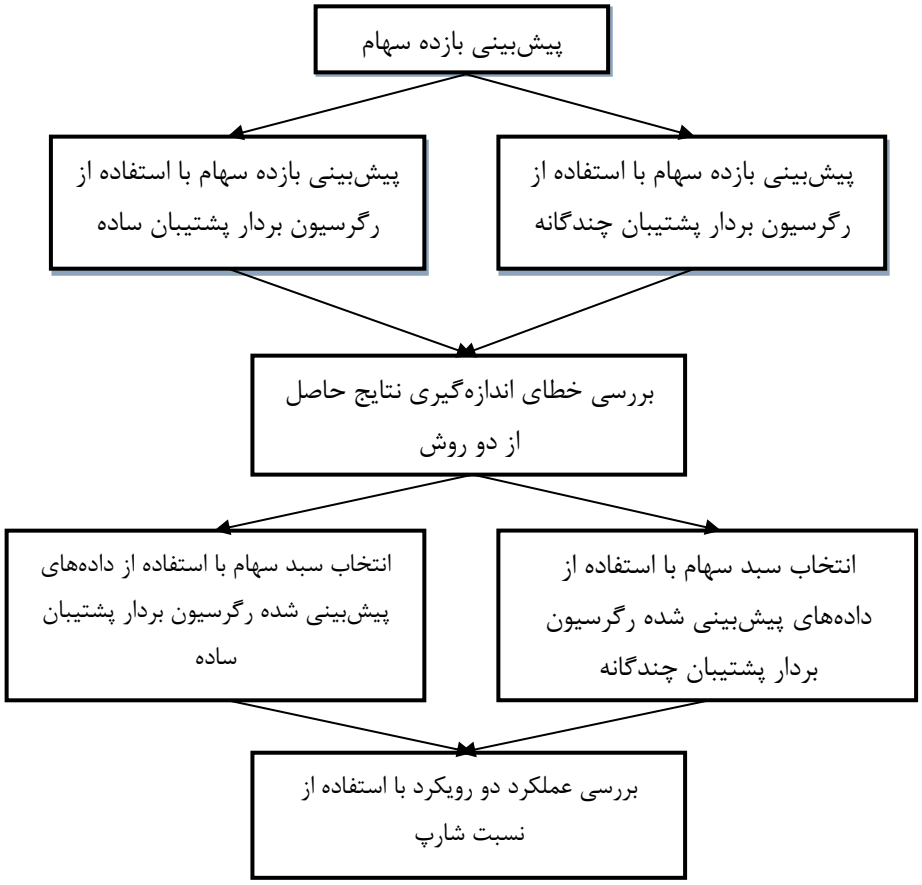

شکل ۳-۱- چارچوب روش تحقیق

۳-۳- جامعه و نمونه آماری تحقیق

به منظور تست مدل مورد بررسی در این پژوهش، داده‌های مورد بررسی، اطلاعات مربوط به بازدهی تعدادی شرکت موجود در صنایع مختلف بازار S&P۵۰۰ می‌باشد.

۳-۴- دوره زمانی مورد بررسی تحقیق

به منظور انجام این پژوهش، دوره زمانی مورد نظر از تاریخ ۲۰۱۶/۱۲/۰۹ تا ۲۰۲۱/۰۲/۰۸ بطور هفتگی که شامل ۲۵۰ داده به صورت تاریخی به ازای هر سهم می‌باشد. این داده‌ها به دو بخش آموزشی و تستی تقسیم‌بندی شده‌اند. داده‌ها برای دوره آموزش از تاریخ ۲۰۱۶/۱۲/۰۹ تا ۲۰۲۰/۱۳/۰۷ شامل ۲۰۰ داده و برای دوره تست از تاریخ ۲۰۲۰/۲۰/۰۷ تا ۲۰۲۱/۰۲/۰۸ شامل ۵۰ داده در نظر گرفته شده‌اند.

۳-۵- روش گردآوری اطلاعات

اطلاعات مربوط سهام از طریق سایت معتبر خارجی[۱] که شامل قیمت‌های تعدیل شده می‌باشد، رصد و دریافت گردیده است.

[۱] Yahoo Finance

۳-۶- ابزار مورد استفاده در انجام تحقیق

به منظور پردازش داده‌ها و پیش‌بینی قیمت سهام و بهینه‌سازی سبد سرمایه‌گذاری به ترتیب از نرم افزارهای MATLAB نسخه ۲۰۱۳a و GAMS با اجرای بر روی لپ تاپ DELL با پردازنده ۲.۲ گیگا هرتزی Corei۷ انجام شده است.

۳-۷- ماشین بردار پشتیبان با خروجی چندگانه

در نظریه یادگیری ماشین، خروجی چندگانه به مسئله‌ای گفته می‌شود که بیش از یک متغیر خروجی وجود داشته باشد. به عبارتی خروجی این مسئله به صورت برداری از متغیرهای خروجی خواهد بود. لذا هدف اصلی در این نوع مسئله، یافتن مدلی برای نگاشت متغیرهای ورودی به یک بردار خروجی می‌باشد. در دنیای واقعی چالش‌های بسیاری از قبیل از دست رفتن داده[۲] و وجود نویز بدلیل چند متغیره بودن خروجی وجود دارد. برای مقابله با این چالش‌ها، ثابت شده است که روش‌های رگرسیونی با خروجی چندگانه عملکرد پیش‌بینی بالاتری در مقایسه با روش‌های رگرسیونی با خروجی یکتا دارند (برنهام و همکاران[۳]، ۱۹۹۹) (هان و همکاران[۴]، ۲۰۱۲). روش‌های رگرسیون چند خروجی با در نظرگرفتن نه تنها روابط بین متغیرهای ورودی و خروجی بلکه روابط بین اهداف وخروجی‌ها، تضمین کننده نمایش بهتر هستند و قابلیت تفسیر بالاتری را دارا می‌باشند (توئیا و همکاران[۵]، ۲۰۱۱). مزیت دیگر رویکردهای چند هدفی این است که می‌توانند مدل‌هایی ساده‌تر با کارایی محاسباتی بهتر تولید کنند (کاسو و همکاران[۶]، ۲۰۰۹).

---

[۲] Missing Data
[۳] Burnham et al.
[۴] Han et al.
[۵] Tuia et al.
[۶] Kocev et al.

روش‌های موجود برای رگرسیون چند خروجی را می‌توان بدین صورت طبقه‌بندی کرد: تکنیک تبدیل[۷] و تکنیک تطبیق الگوریتم[۸]. تکنیک تبدیل، به عنوان مدل سنتی و محلی شناخته می‌شود و مسئله خروجی چندگانه را به چندین مسئله تک خروجی به صورت مستقل تبدیل می‌کند و سپس با حل هر کدام از تک خروجی‌ها و تجمیع آن‌ها جواب مسئله اصلی را تعیین خواهد نمود. تکنیک تطبیق الگوریتم، با اصلاح برخی از الگوریتم‌های در دسترس در مدل تک خروجی، اقدام به حل مسئله چند خروجی کرده و از تبدیل آن صرف نظر می‌کند. از این الگوریتم علاوه بر پیش‌بینی خروجی‌ها، برای مدل کردن و تفسیر وابستگی بین خروجی‌ها نیز استفاده می‌شود. مسائلی که به طور معمول در این الگوریتم مورد بررسی قرار می‌گیرد، مدل‌سازی روابط بین خروجی‌ها به صورت همزمان می‌باشد به عبارت دیگر در صورتی‌که بین متغیرهای خروجی همبستگی برقرار نباشد و قابل صرف نظر باشد، مسئله معادل یک مدل با چندین خروجی یکتا است. اما اگر بین متغیرهای خروجی همبستگی قابل صرف نظر نباشد، لازم می‌باشد از تکنیک‌های تطبیق استفاده نمود (برچانی و همکاران[۹]، ۲۰۱۵). در سال ۲۰۱۳، ژو و همکاران[۱۰] به این نوع خروجی اشاره می‌کنند و برای حل آن یک الگوریتم ارائه دادند که توضیح داده خواهد شد (ژو و همکاران،۲۰۱۳).

۳-۹- رگرسیون بردار پشتیبان حداقل مربعات[۱۱]

با تغییر محدودیت‌های نابرابر در رگرسیون بردار پشتیبان با محدودیت‌های برابر، رگرسیون بردار پشتیبان حداقل مربعات، مسئله برنامه‌ریزی غیرخطی محدب را به یک مسئله برنامه‌ریزی خطی محدب تبدیل خواهد کرد (سایکینز و وندوال[۱۲]، ۲۰۰۲). گستل و همکاران[۱۳] در سال ۲۰۰۴ در طی یک مطالعه تجربی دقیق دریافتند که در این الگوریتم سرعت یادگیری داده‌های آموزشی در مقایسه با رگرسیون بردار پشتیبان بسیار

---

[۷] Transformation
[۸] Algorithm adaptation
[۹] Borchani et al.
[۱۰] Xu et al.
[۱۱] Least_squares support vector regression machine (LS_SVR)
[۱۲] Suykens & Vandewalle
[۱۳] Gestel et al.

بالاتر می‌باشد. بنابراین این الگوریتم مورد توجه بسیاری بوده است. با وجود کارایی این روش باید بیان کرد که روش مذکور قابلیت نگاشت به یک خروجی چندگانه را ندارد. حل مشکل پیش رو، نحوه مدلسازی خروجی‌های مختلف به صورت همزمان می‌باشد (ژو و همکاران،۲۰۱۳).

۳-۹-۱- رگرسیون بردار پشتیبان حداقل مربعات با خروجی چندگانه[۱۴]

ابتدا فرض کنید تمام شیب ابرصفحه‌ها $w_i \in R^{n_h}$ به صورت $w_i = w_. + v_i$ نوشته می‌شوند که بردارهای $v_i \in R^{n_h}$ دارای اطلاعات ویژه و خاص و $w_. \in R^{n_h}$ دارای اطلاعات مشترک هستند که بردار میانگین نام دارند و i برابر با تعداد سهام می‌باشد.

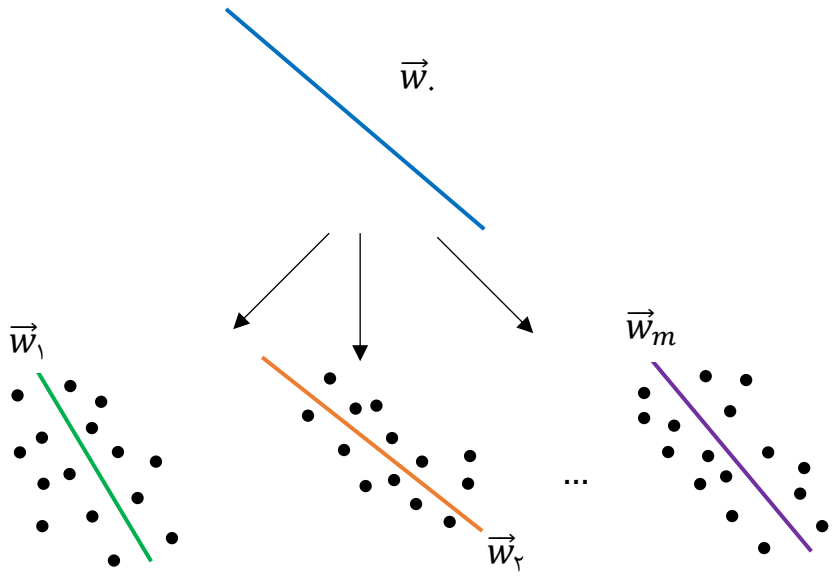

[۱۴] Multi_output Least_squares support vector regression machine (MLS_SVR)

شکل ۳-۱- مثالی از درک اصول رگرسیون بردار پشتیبان حداقل مربعات با خروجی چندگانه

برای حل $w_0 \in R^{n_h}$، $V = (v_1, v_2, \dots, v_m) \in R^{n_h * m}$ و $b = (b_1, b_2, \dots, b_m)^T \epsilon R^m$ به صورت همزمان، می‌توان مدل ریاضی زیر را حداقل نمود.

$$\min_{w_0, V, b} \mathcal{J}(w_0, V, b) = \frac{1}{2} w_0^T w_0 + \frac{1}{2}\frac{\lambda}{m} trace(V^T V) \tag{۱-۳}$$

$$+ \frac{\gamma}{2m} trace(\Xi^T \Xi) + repmat(b^T, l, 1)$$

$$s.t.\ \ Y = Z^T W + repmat(b^T, l, 1) + \Xi \tag{۲-۳}$$

طوریکه $\Xi = \left(\xi_1, \xi_2, \dots, \xi_m\right) \in R^{l*m}$ ، $W = (w_0 + v_1, w_0 + v_2, \dots, w_0 + v_m) \in R^{n_h * m}$.

$Z = \left(\varphi(x_1), \varphi(x_1), \dots, \varphi(x_l)\right) \in R^{n_h * l}$ و λ ، γ دو پارمتر همواره مثبت هستند. مدل لاگرانژ رابطه بالا به صورت زیر خواهد بود:

$$\mathcal{L}(w_0, V, b, \Xi, \mathrm{A}) = \mathcal{J}(w_0, V, b) - trace(A^T (Z^T W) + repmat(b^T, l, 1) + \Xi - \mathrm{Y}) \tag{۳-۳}$$

طوریکه $A = (a_1, a_2, \dots, a_m) \in R^{l*m}$ ماتریسی از ضرایب لاگرانژ می‌باشد. شرایط KKT به صورت زیر اعمال می‌شوند:

$$\frac{\partial \mathcal{L}}{\partial w_0} = 0 \ \ \Rightarrow \ \ w_0 = \sum_{i=1}^{m} Z a_i \tag{۴-۳}$$

$$\frac{\partial \mathcal{L}}{\partial V} = 0 \ \ \Rightarrow \ \ V = \frac{m}{\lambda} Z A \tag{۵-۳}$$

$$\frac{\partial \mathcal{L}}{\partial b} = 0 \ \ \Rightarrow \ \ A^T 1_l = 0_l \tag{۶-۳}$$

$$\frac{\partial \mathcal{L}}{\partial \Xi} = 0 \ \ \Rightarrow \ \ A = \gamma \Xi \tag{۷-۳}$$

$$\frac{\partial \mathcal{L}}{\partial A} = 0 \ \ \Rightarrow \ \ (Z^T W) + repmat(b^T, l, 1) + \Xi - \mathrm{Y} = 0_{l*m} \tag{۸-۳}$$

از روابط بالا می‌توان پی برد که $w.$ یک ترکیب خطی از v_i می‌باشد یا به عبارتی:

$$w. = \frac{\lambda}{m}\sum_{i=1}^{m} v_i \qquad (۹-۳)$$

به کمک رابطه ۳-۹ روابط ۳-۱ و ۳-۲ را به صورت زیر ساده می‌شوند:

$$\min_{V,b} \mathcal{J}(V,b) = \frac{1}{2}\frac{\lambda^2}{m^2} V 1_m 1_m^T V^T + \frac{1}{2}\frac{\lambda}{m} trace(V^T V) \qquad (۱۰-۳)$$

$$+\frac{\gamma}{2m} trace(\Xi^T \Xi)$$

$$s.t.\ \ Y = Z^T V + repmat\left(\frac{\lambda}{m} Z^T V 1_m, 1, m\right) + \ repmat(b^T, l, 1) + \Xi \qquad (۱۱-۳)$$

در اینجا می‌توان با استفاده از رویکرد سایکینز (۲۰۰۲) W و Ξ حذف نمود و سیستم خطی شرایط KKT را به صورت زیر بدست آورد:

$$\begin{bmatrix} 0_{ml*m} & P^T \\ P & H \end{bmatrix} \begin{bmatrix} b \\ a \end{bmatrix} = \begin{bmatrix} 0_m \\ y \end{bmatrix} \qquad (۱۲-۳)$$

طوریکه:

$$P = blockdiag\left(\overbrace{1_l, 1_l, \dots, 1_l}^{m}\right)$$

$$H = \Omega + \gamma^{-1} I_{ml} + \frac{m}{\lambda} B$$

$$B = blockdiag(\Omega_1, \Omega_2, \dots, \Omega_m) \in \mathbb{R}^{n*n}$$

$$\Omega = Z^T Z \qquad (۱۳-۳)$$

$$a = (a_1^T, a_2^T, \dots, a_m^T)^T$$

$$y = (y_1^T, y_2^T, \dots, y_m^T)^T$$

اکنون با بدست آوردن a^* و b^* می‌توان تابع تصمیم دارای همبستگی را با در نظر گرفتن خروجی چندگانه به صورت زیر مدلسازی کرد:

$$f(x) = \varphi(x)^T W^* + b^{*T} = \varphi(x)^T repmat(w_{\cdot}^*, ۱, m) + \varphi(x)^T V^* + b^{*T} \qquad (۱۴-۳)$$

$$= \varphi(x)^T repmat\left(\sum_{i=۱}^{m} Za_i^*, ۱, m\right) + \frac{m}{\lambda}\varphi(x)^T ZA^* + b^{*T}$$

$$= repmat\left(\sum_{i=1}^{m}\sum_{j}^{l} a_{ij}^* K(x, x_j)\right) + \frac{m}{\lambda}\sum_{j}^{l} a_j^* K(x, x_j) + b^{*T}$$

اگر به رابطه ۳-۱۲ توجه کنید متوجه خواهید شد که این ماتریس یک ماتریس مثبت معین نیست، لذا حل آن به صورت مستقیم دشوار می‌باشد. برای حل این مسئله ژو و همکاران در سال ۲۰۱۳ یک مدل به صورت زیر ارائه دادند:

$$\begin{bmatrix} S & ۰_{ml*ml} \\ ۰_{m*m} & H \end{bmatrix} \begin{bmatrix} b \\ H^{-۱}Pb + a \end{bmatrix} = \begin{bmatrix} P^T H^{-۱} y \\ y \end{bmatrix} \qquad (۱۵-۳)$$

می‌توان پی برد که $S = P^T H^{-۱} P$ یک ماتریس مثبت معین می‌باشد و بدین ترتیب رابطه (۳-۱۵) نیز یک سیستم خطی جدید به صورت مثبت معین خواهد بود. b و a به ترتیب مراحل زیر بدست می‌آیند:

حل η و v از رابطه زیر:

$$\boldsymbol{H\eta = P, Hv = y} \qquad (۱۶-۳)$$

محاسبه $\boldsymbol{S}$ به صورت زیر تعریف می‌گردد:

$$S = P^T \eta \qquad (۱۷-۳)$$

در انتها محاسبه b و a به صورت زیربدست خواهند آمد:

$$b = S^{-۱}\eta^T y, a = v - \eta b \qquad (۱۸-۳)$$

با استفاده از روابط بالا می‌توان فرآیند آموزش را با حل دو مجموعه معادله خطی با ضرایب ماتریس مثبت معین یعنی H حل نمود. از این روی، می‌توان بسیاری از روش‌های بهینه‌سازی سریع و کارآمد را از این روش اتخاذ نمود. از طرفی از آنجا که تعداد خروجی‌ها نسبت به تعداد نمونه‌ها خیلی کمتر است، به راحتی می‌توان معکوس ماتریس S را تنها با ضرب ماتریس‌ها بدست آورد.

در این پژوهش در مسئله بهینه‌سازی پرتفوی به جای استفاده از مدل مارکویتز و کمینه‌سازی واریانس بازده پیش‌بینی شده سهام از کمینه‌سازی خطای پیش‌بینی به عنوان تابع هدف استفاده شده است. به عبارت دیگر در این مدل اختلاف بین مقدار واقعی و مقدار پیش‌بینی شده (ریسک سیستماتیک) به عنوان ریسک تعریف می‌شود که این عمل به هدف تولید خطاهای پیش‌بینی با توزیع نرمال از سری بازده‌های غیر نرمال صورت می‌گیرد (فریتاس و همکاران، ۲۰۰۹). مدل مذکور که همان پایه و اساس آماری مدل میانگین_ واریانس مارکویتز را دارا می‌باشد به صورت زیر تعریف می‌گردد:

$$min \quad \hat{V} = \hat{\sigma}_p^۲ = \sum_{i=۱}^{N}\sum_{j=۱}^{N} w_i w_j \sigma_{ij} \tag{۱۹-۳}$$

$$Subject\ to \quad \sum_{i=1}^{N} w_i \mu_i = R^* \tag{۲۰-۳}$$

$$\sum_{i=۱}^{N} w_i = ۱ \tag{۲۱-۳}$$

$$۰ \le w_i \le ۱ \qquad , i = ۱, \dots, N \tag{۲۲-۳}$$

$$\sigma_{ij} = \frac{۱}{n-۱}\sum_{t=۱}^{n} \varepsilon_{it}\varepsilon_{jt} \tag{۲۳-۳}$$

$$\varepsilon_t = r_t - \hat{r}_t$$

همانطور که در مدل انتخاب سبد بالا مشاهده می‌گردد، تابع هدف بر خلاف مدل مارکویتز ریسک سیستماتیک را در نظر می‌گیرد. برای این منظور ماتریس واریانس کواریانس از تفاضل مقدار واقعی و مقدار پیش‌بینی شده طبق رابطه ۳-۲۳ و ۳-۲۲ بدست می‌آید.

۳-۱۰- جمع‌بندی و نتیجه‌گیری

سرمایه‌گذاران در بازارهای مالی به دنبال پیش‌بینی بازده قیمت سهام با کمترین میزان خطا هستند که در این پژوهش به دنبال ارائه مدلی متفاوت از مدل‌های ارائه شده تا به حال، برآمدیم که هدف این مدل کاهش میزان خطا پیش‌بینی و افزایش بازده با ریسک یکسان به منظور بهینه‌سازی سبد سهام بوده است.

در این فصل در ابتدا، به معرفی نمونه آماری، نحوه گردآوری اطلاعات و دوره زمانی مورد بررسی تحقیق اشاره شد. در ادامه نیز توضیحات مفصلی در رابطه با الگوریتم ماشین بردار پشتیبان که برای حل مسئله مورد استفاده قرار خواهد گرفت، داده شد. سپس در مرحله دوم با استفاده از داده‌های پیش‌بینی شده به عنوان داده‌های ورودی در انتخاب سبد سهام مورد استفاده قرار گرفتند. در فصل بعد، نتایج و بررسی‌های انجام شده در رابطه با ارزیابی عملکرد مدل تشریح خواهد شد.

فصل چهارم

تجزیه و تحلیل داده‌ها و اطلاعات

۴-۱- مقدمه

در این فصل برای راستی آزمایی و ارزیابی مدل پیشنهادی برای انتخاب سبد سهام سرمایه‌گذاری، به حل آن با استفاده از داده‌های واقعی پرداخته و در آخر به تحلیل داده‌ها می‌پردازیم. بستر مطالعه، بازار سهام آمریکا و مشخصاً شاخص S&P۵۰۰ است. ابتدا تعدادی از سهام (۷ سهم) از صنایع مختلف به صورت تصادفی، جهت سرمایه‌گذاری مد نظر قرار می‌گیرند. لازم به ذکر است که اطلاعات مربوط به سهام از تارنمای یاهوفایننس[۱] استخراج شده است.

۴-۲- پیش‌بینی بازده آتی سهام با رگرسیون بردار پشتیبان

در این بخش، مدل پیشنهادی رگرسیون بردار پشتیبان با یک مثال عددی پیاده‌سازی می‌شود. برای این امر اطلاعات مربوط به ۷ سهام انتخابی در بازه زمانی ۲۰۱۶/۱۲/۰۹ تا ۲۰۲۱/۰۲/۰۸ به صورت هفتگی از تارنمای یاهو فایننس استخراج و بازده هفتگی مربوط به هر یک از سهام محاسبه شده است. با توجه به مطالب ذکر شده و مطالعات انجام شده، رگرسیون بردار پشتیبان با خروجی چندگانه به عنوان الگوریتم مورد استفاده در پیش‌بینی بازده آتی سهام مورد استفاده قرار می‌گیرد. تابع گوسین به عنوان تابع کرنل مورد استفاده قرار گرفته است. لازم به ذکر است که در الگوریتم طراحی شده تنها از اولین قیمت، کمترین

[۱] www.yahoofinance.com

قیمت، بیشترین قیمت، قیمت پایانی دیروز به عنوان متغیرهای ورودی مورد استفاده قرار گرفته‌اند. از نرم افزار MATLAB برای کدنویسی در بخش پیش‌بینی و از نرم افزار گمز برای کدنویسی در بخش انتخاب سبد سهام بهینه استفاده شده‌اند. مدل رگرسیون خروجی چندگانه برای تمام سهم یکبار و مدل رگرسیون یکتا به ازای هر سهم اجرا شد و با توجه به شاخص میانگین مربعات خطا، جذر میانگین مربع خطا و ریشه دوم میانگین مربعات خطا بهترین پیش‌بینی بین دو روش مذکور انتخاب و مورد استفاده قرار گرفتند. همان‌گونه که قبلاً گفته شد برای پیش‌بینی بازده آتی سهام، قیمت‌های سهام از تاریخ ۲۰۱۶/۱۲/۰۹ تا ۲۰۲۱/۰۲/۰۸ به صورت هفتگی جمع‌آوری شدند و سپس بازده هفتگی مربوط به هر یک محاسبه و در نهایت این بازده‌ها به عنوان متغیرهای ورودی رگرسیون بردار پشتیبان به منظور پیش‌بینی مورد استفاده قرار گرفته‌اند.

جدول ۴-۱- اسامی و ترتیب سهام به همراه صنایع مربوطه

	سهم ۱	سهم ۲	سهم ۳	سهم ۴	سهم ۵	سهم ۶	سهم ۷
سهام	COST	CHRW	AWK	AMZN	AIZ	ABBV	AAPL
صنعت	Consumer Staples	Industrial	Utility	Consumer Discretionary	Financial	Health Care	Informaton Technology

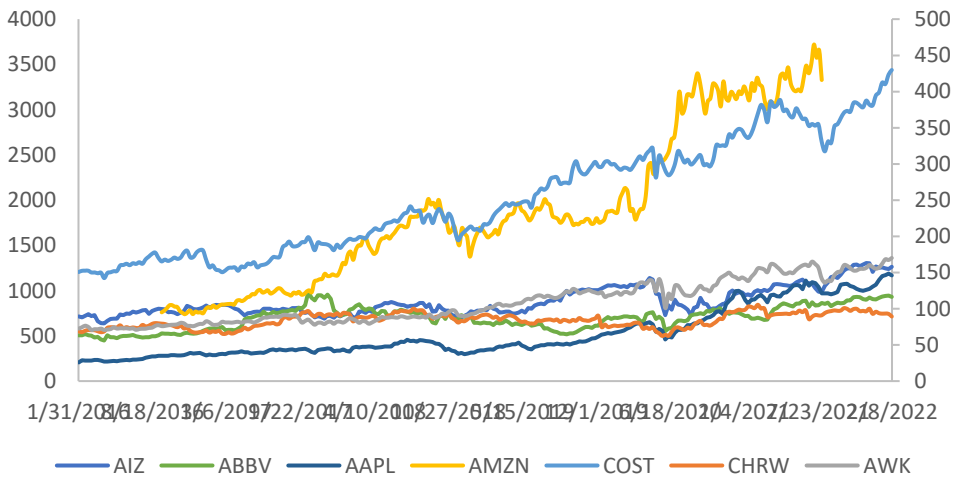

شکل ۴-۱- روند قیمتی در سهام منتخب در بازه زمانی ۲۰۱۶/۱۲/۰۹ تا ۲۰۲۱/۰۲/۰۸

حال به کمک شاخص میانگین مربعات خطا، جذر میانگین مربع خطا و درصد میانگین قدرمطلق خطا، خطای پیش‌بینی رگرسیون بردار پشتیبان خروجی چندگانه و یکتا را محاسبه می‌کنیم تا بهترین روش پیش‌بینی انتخاب گردد.که نتایج آن در جدول زیر نشان داده شده است.

جدول ۴-۲- خطای پیش‌بینی حاصل از دو رویکرد

سهام	COST	CHRW	AWK	AMZN	AIZ	ABBV	AAPL
پیش‌بینی با استفاده از رگرسیون بردار پشتیبان با خروجی چندگانه							
MAD	۰.۰۱۴۷	۰.۰۱۵۶	۰.۰۱۵۴	۰.۰۱۹۸	۰.۰۱۶۲	۰.۰۱۶۲	۰.۰۲۲۳
MSE	۰.۰۰۰۳	۰.۰۰۰۵	۰.۰۰۰۴	۰.۰۰۰۸	۰.۰۰۰۸	۰.۰۰۰۴	۰.۰۰۰۸
RMSE	۰.۰۱۸۲	۰.۰۲۱۸	۰.۰۱۹۸	۰.۰۲۸۰	۰.۰۲۷۵	۰.۰۲۰۷	۰.۰۲۸۲
پیش‌بینی با استفاده از رگرسیون بردار پشتیبان با خروجی یکتا							
MAD	۰.۰۲۳۹	۰.۰۳۵۷	۰.۰۲۳۳	۰.۰۳۳۹	۰.۰۲۰۹	۰.۰۲۰۱	۰.۰۳۰۴
MSE	۰.۰۰۱۰	۰.۰۰۱۷	۰.۰۰۰۸	۰.۰۰۱۶	۰.۰۰۰۹	۰.۰۰۰۷	۰.۰۰۱۶
RMSE	۰.۰۳۱۰	۰.۰۴۱۵	۰.۰۲۸۵	۰.۰۴۰۳	۰.۰۳۰۴	۰.۰۲۵۸	۰.۰۳۹۶

انحراف معیار خطای حاصل از پیش‌بینی نیز به صورت جدول ۴-۵ تعریف شده است.

جدول ۴-۵- خطای پیش‌بینی حاصل از دو رویکرد

انحراف معیار خطای حاصل از پیش‌بینی با کمک رگرسیون چندگانه		انحراف معیار خطای حاصل از پیش‌بینی با کمک رگرسیون یکتا	
MAD	۰.۰۰۲۸	MAD	۰.۰۰۶۳
MSE	۰.۰۰۰۲	MSE	۰.۰۰۰۴
RMSE	۰.۰۰۴۲	RMSE	۰.۰۰۶۴

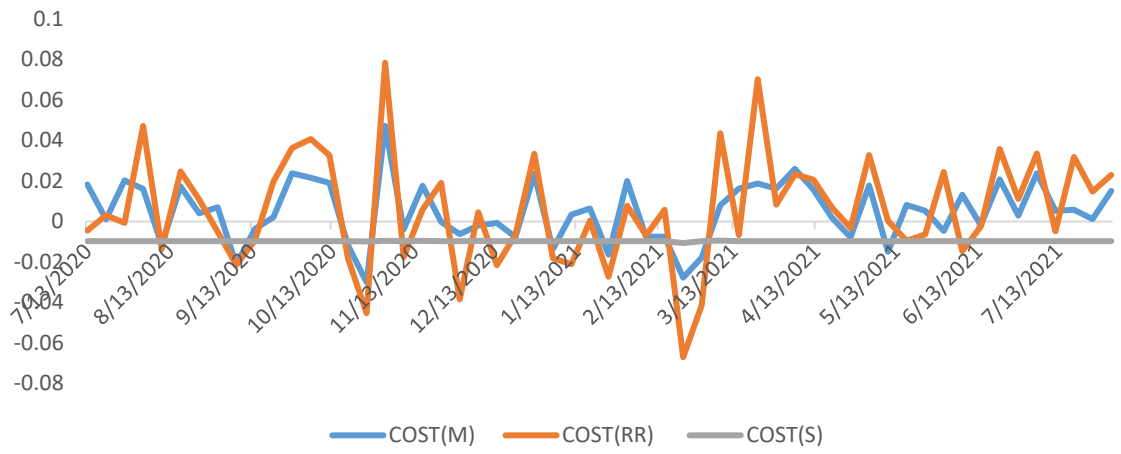

شکل ۴-۲- روند بازده در سهم منتخب در بازه زمانی ۲۰۲۰/۱۳/۰۷ تا ۲۰۲۱/۰۲/۰۸

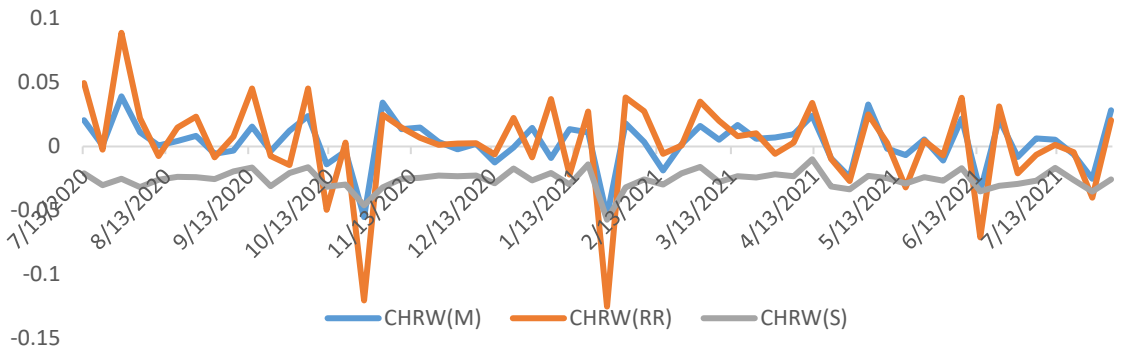

شکل ۴-۳- روند بازده در سهم منتخب در بازه زمانی ۲۰۲۰/۱۳/۰۷ تا ۲۰۲۱/۰۲/۰۸

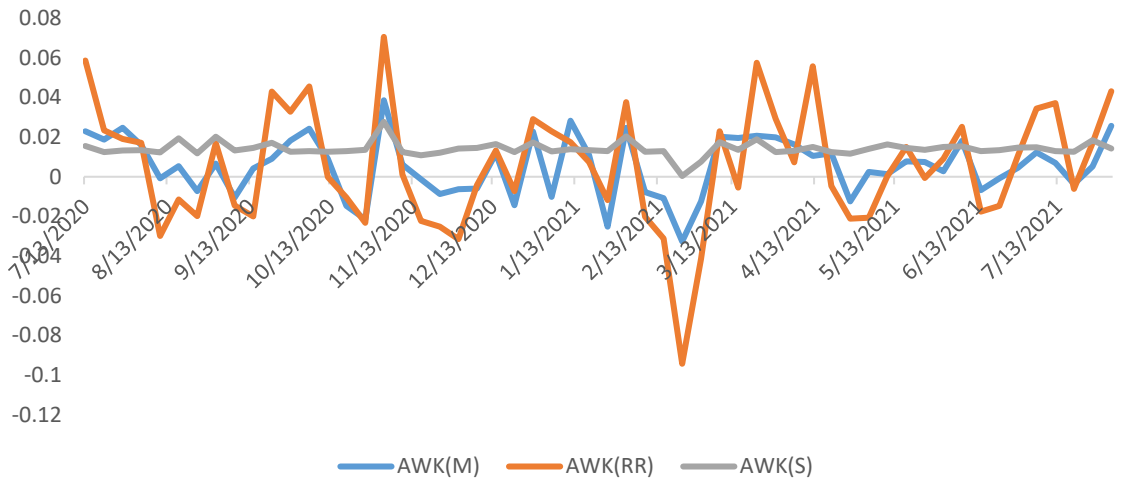

شکل ۴-۴- روند بازده در سهم منتخب در بازه زمانی ۲۰۲۰/۱۳/۰۷ تا ۲۰۲۱/۰۲/۰۸

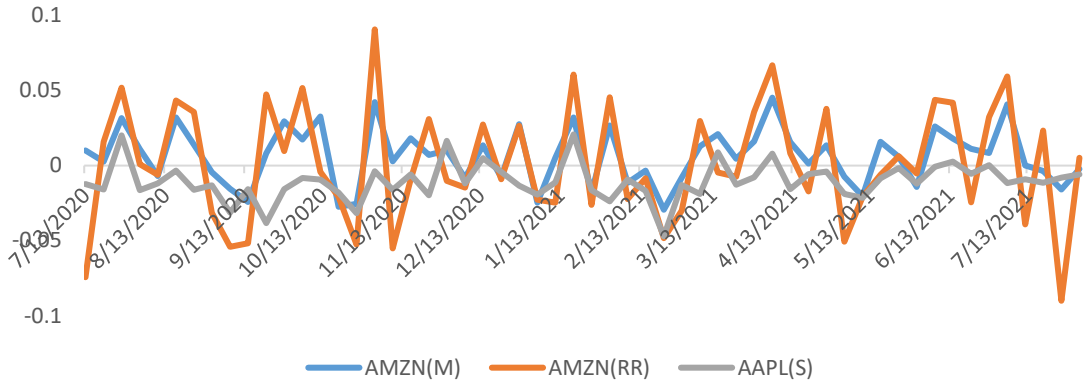

شکل ۴-۵- روند بازده در سهم منتخب در بازه زمانی ۲۰۲۰/۱۳/۰۷ تا ۲۰۲۱/۰۲/۰۸

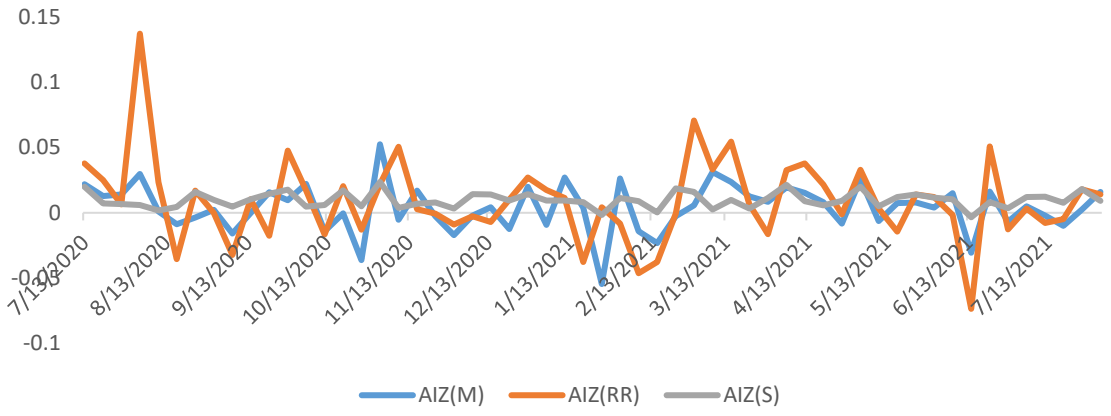

۴-۶- روند بازده در سهم منتخب در بازه زمانی ۲۰۲۰/۱۳/۰۷ تا ۲۰۲۱/۰۲/۰۸

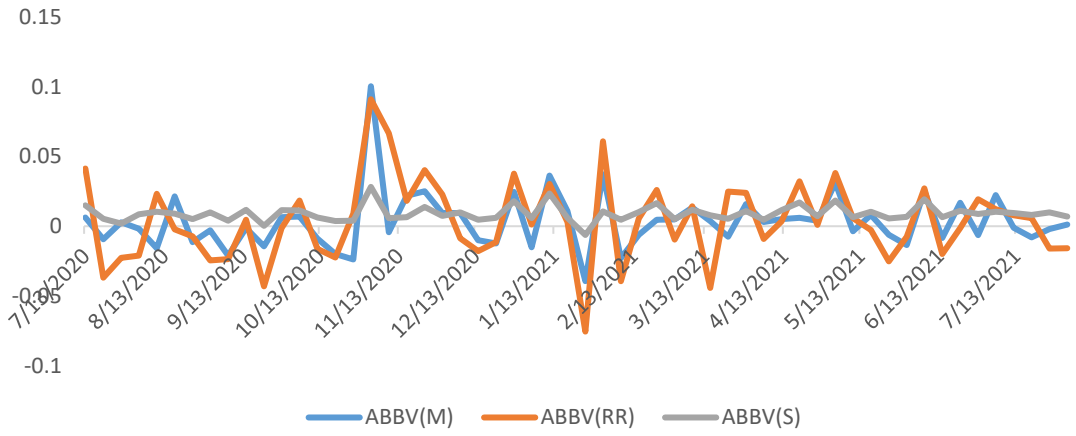

شکل ۴-۷- روند بازده در سهم منتخب در بازه زمانی ۲۰۲۰/۱۳/۰۷ تا ۲۰۲۱/۰۲/۰۸

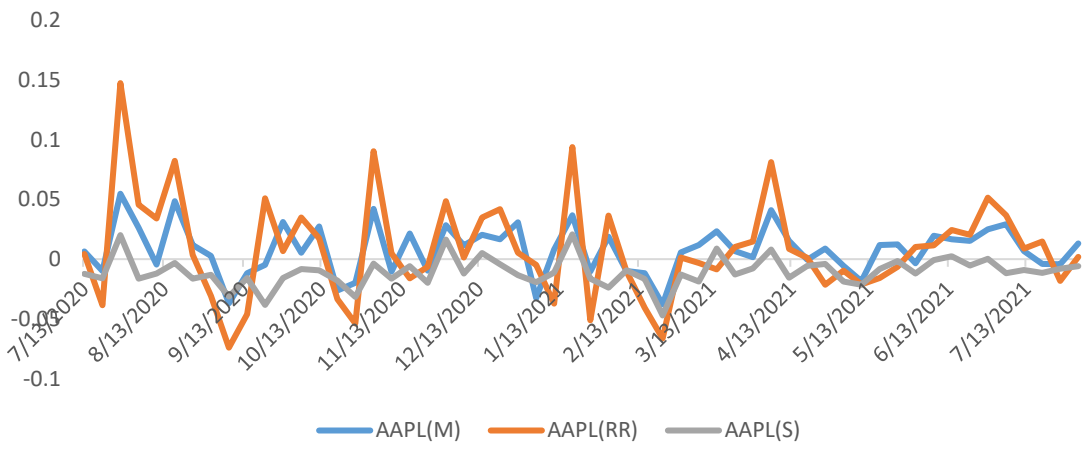

شکل ۴-۸- روند بازده در سهم منتخب در بازه زمانی ۲۰۲۰/۱۳/۰۷ تا ۲۰۲۱/۰۲/۰۸

همانطور که در نمودارهای روند بازده در سهام منتخب مشاهده می‌شود، پیش‌بینی بازده با خروجی چندگانه، هم پوشانی بیشتری را نسبت به خروجی یکتا فراهم می‌آورد.

۴-۳- حل مسئله انتخاب سبد سهام بهینه

همانطور که قبلاً نیز گفته شد هدف از این مثال تصمیم‌گیری در رابطه با میزان سرمایه‌گذاری و انتخاب بهینه سبد سهام به کمک پیش‌بینی در افق زمانی هفتگی است. مدل پیشنهادی در نرم افزار گمز کدنویسی و اجرا شده است. در ادامه با استفاده از اطلاعات حاصل از پیش‌بینی بازده‌های آتی سهام مدل پیشنهادی انتخاب بهینه سهام به ازای ریسک و بازده‌های مورد انتظار مختلف حل می‌شود تا میزان سرمایه‌گذاری بر روی هر سهم مشخص گردد. نتایج حاصل که شامل تصمیم‌گیری در مورد میزان سرمایه‌گذاری بر روی هر یک از سهام و به همراه مقادیر تابع هدف آنان می‌باشد در جداول زیر آورده شده است.

جدول ۴-۶- ماتریس واریانس کوارایانس حاصل از تفاضل داده‌های واقعی و پیش‌بینی (پیش‌بینی ساده)

	COST	CHRW	AWK	AMZN	AIZ	ABBV	AAPL
COST	۰.۰۰۰۳۳۱	۰.۰۰۰۰۰۵	۰.۰۰۰۱۲۵	۰.۰۰۰۱۴۱	۰.۰۰۰۰۱۲	۰.۰۰۰۰۰۴	۰.۰۰۰۰۹۰
CHRW	۰.۰۰۰۰۰۵	۰.۰۰۰۴۴۷	۰.۰۰۰۰۱۱	۰.۰۰۰۰۷۰	-۰.۰۰۰۰۲۴	۰.۰۰۰۰۴۴	۰.۰۰۰۲۶۵
AWK	۰.۰۰۰۱۲۵	۰.۰۰۰۰۱۱	۰.۰۰۰۳۹۳	۰.۰۰۰۰۷۱	-۰.۰۰۰۰۴۵	-۰.۰۰۰۰۰۳	۰.۰۰۰۱۱۰
AMZN	۰.۰۰۰۱۴۱	۰.۰۰۰۰۷۰	۰.۰۰۰۰۷۱	۰.۰۰۰۷۵۸	-۰.۰۰۰۲۶۹	-۰.۰۰۰۱۰۹	۰.۰۰۰۳۷۲
AIZ	۰.۰۰۰۰۱۲	-۰.۰۰۰۰۲۴	-۰.۰۰۰۰۴۵	-۰.۰۰۰۲۶۹	۰.۰۰۰۷۳۱	۰.۰۰۰۰۲۷	-۰.۰۰۰۱۳۱
ABBV	۰.۰۰۰۰۰۴	۰.۰۰۰۰۴۴	-۰.۰۰۰۰۰۳	-۰.۰۰۰۱۰۹	۰.۰۰۰۰۲۷	۰.۰۰۰۴۳۰	۰.۰۰۰۰۴۴
AAPL	۰.۰۰۰۰۹۰	۰.۰۰۰۲۶۵	۰.۰۰۰۱۱۰	۰.۰۰۰۳۷۲	-۰.۰۰۰۱۳۱	۰.۰۰۰۰۴۴	۰.۰۰۰۷۹۸

جدول ۴-۷- ماتریس واریانس کوارایانس حاصل از تفاضل داده‌های واقعی و پیش‌بینی (پیش‌بینی چندگانه)

	COST	CHRW	AWK	AMZN	AIZ	ABBV	AAPL
COST	۰.۰۰۰۷۲۷	۰.۰۰۰۱۹۹	۰.۰۰۰۴۱۶	۰.۰۰۰۴۳۷	۰.۰۰۰۱۷۳	۰.۰۰۰۱۳۱	۰.۰۰۰۴۲۲
CHRW	۰.۰۰۰۱۹۹	۰.۰۰۰۹۲۳	۰.۰۰۰۲۰۳	۰.۰۰۰۲۱۱	۰.۰۰۰۲۵۹	۰.۰۰۰۱۹۱	۰.۰۰۰۴۵۰
AWK	۰.۰۰۰۴۱۶	۰.۰۰۰۲۰۳	۰.۰۰۰۷۴۳	۰.۰۰۰۳۰۱	۰.۰۰۰۱۲۹	۰.۰۰۰۱۰۱	۰.۰۰۰۳۴۶
AMZN	۰.۰۰۰۴۳۷	۰.۰۰۰۲۱۱	۰.۰۰۰۳۰۱	۰.۰۰۱۳۷۲	-۰.۰۰۰۱۹۸	۰.۰۰۰۰۶۷	۰.۰۰۰۸۳۰
AIZ	۰.۰۰۰۱۷۳	۰.۰۰۰۲۵۹	۰.۰۰۰۱۲۹	-۰.۰۰۰۱۹۸	۰.۰۰۰۹۲۴	۰.۰۰۰۰۳۱	۰.۰۰۰۰۴۲
ABBV	۰.۰۰۰۱۳۱	۰.۰۰۰۱۹۱	۰.۰۰۰۱۰۱	۰.۰۰۰۰۹۷	۰.۰۰۰۰۳۱	۰.۰۰۰۶۳۵	۰.۰۰۰۲۰۸
AAPL	۰.۰۰۰۴۲۲	۰.۰۰۰۴۵۰	۰.۰۰۰۳۴۶	۰.۰۰۰۸۳۰	۰.۰۰۰۰۴۲	۰.۰۰۰۲۰۸	۰.۰۰۱۲۱۳

جدول ۴-۸- سناریوهای ایجاد شده برای حداقل بازده مورد نیاز در آخرین هفته (پیش‌بینی چندگانه)

ردیف	بازده	COST	CHRW	AWK	AMZN	AIZ	ABBV	AAPL	ریسک
۱	۰.۰۰۱۷	۰.۱۵۳	۰.۱۲۹	۰.۱۶۰	۰.۱۶۱	۰.۰۱۸۱	۰.۲۱۶	۰.۰	۰.۰۰۹
۲	۰.۰۱۵	۰.۱۵۳	۰.۱۷۱	۰.۱۹۷	۰.۱۲۵	۰.۱۷۷	۰.۱۷۶	۰.۰	۰.۰۰۹
۳	۰.۰۲۰	۰.۱۵۷	۰.۲۷۱	۰.۲۸۳	۰.۰۴۰	۰.۱۶۷	۰.۰۸۲	۰.۰	۰.۰۱۰
۴	۰.۰۲۱	۰.۱۵۷	۰.۲۹۱	۰.۳۰۰	۰.۰۲۲	۰.۱۶۶	۰.۰۶۳	۰.۰	۰.۰۱۱
۵	۰.۰۲۲	۰.۱۵۸	۰.۳۱۱	۰.۳۱۷	۰.۰۰۵	۰.۱۶۴	۰.۰۴۵	۰.۰	۰.۰۱۱
۶	۰.۰۲۳	۰.۱۴۹	۰.۳۳۳	۰.۳۳۸	۰.۰	۰.۱۶۵	۰.۰۱۶	۰.۰	۰.۰۱۲
۷	۰.۰۲۴	۰.۱۰۴	۰.۳۶۳	۰.۳۷۵	۰.۰	۰.۱۵۸	۰.۰	۰.۰	۰.۰۱۲
۸	۰.۰۲۵	۰.۰۳۲	۰.۴۰۱	۰.۴۲۴	۰.۰	۰.۱۴۲	۰.۰	۰.۰	۰.۰۱۳
۹	۰.۰۲۶	۰.۰	۰.۴۵۴	۰.۴۵۸	۰.۰	۰.۰۸۸	۰.۰	۰.۰	۰.۰۱۴
۱۰	۰.۰۲۷	۰.۰	۰.۵۱۹	۰.۴۸۰	۰.۰	۰.۰	۰.۰	۰.۰	۰.۰۱۵
۱۱	۰.۰۲۸	۰.۰	۰.۹۱۶	۰.۰۸۴	۰.۰	۰.۰	۰.۰	۰.۰	۰.۰۲۰
۱۲	۰.۰۲۸۲	۰.۰	۱.۰	۰.۰	۰.۰	۰.۰	۰.۰	۰.۰	۰.۰۲۲

جدول ۴-۹- سناریوهای ایجاد شده برای حداقل بازده مورد نیاز در آخرین هفته (پیش‌بینی ساده)

ردیف	بازده	COST	CHRW	AWK	AMZN	AIZ	ABBV	AAPL	ریسک
۱	۰.۰	۰.۰۸۰	۰.۰۸۷	۰.۱۷۷	۰.۰۹۹	۰.۲۲۲	۰.۳۳۶	۰.۰	۰.۰۰۹
۲	۰.۰۱۱	۰.۰	۰.۰	۰.۲۶۰	۰.۱۵۷	۰.۲۴۹	۰.۳۳۴	۰.۰	۰.۰۰۹
۳	۰.۰۱۲	۰.۰	۰.۰	۰.۳۱۷	۰.۲۱۸	۰.۲۲۳	۰.۲۴۱	۰.۰	۰.۰۱۰
۴	۰.۰۱۳	۰.۰	۰.۰	۰.۳۷۴	۰.۲۷۹	۰.۱۹۷	۰.۱۴۹	۰.۰	۰.۰۱۱
۵	۰.۰۱۴	۰.۰	۰.۰	۰.۴۳۲	۰.۳۴۰	۰.۱۷۱	۰.۰۵۷	۰.۰	۰.۰۱۱
۶	۰.۰۱۵	۰.۰	۰.۰	۰.۴۸۲	۰.۴۱۴	۰.۱۰۴	۰.۰	۰.۰	۰.۰۱۲
۷	۰.۰۱۶	۰.۰	۰.۰	۰.۴۴۲	۰.۵۵۸	۰.۰	۰.۰	۰.۰	۰.۰۱۲
۸	۰.۰۱۷	۰.۰	۰.۰	۰.۱۳۷	۰.۸۶۳	۰.۰	۰.۰	۰.۰	۰.۰۱۳
۹	۰.۰۱۷۴	۰.۰	۰.۰	۰.۰	۱.۰	۰.۰	۰.۰	۰.۰	۰.۰۱۴

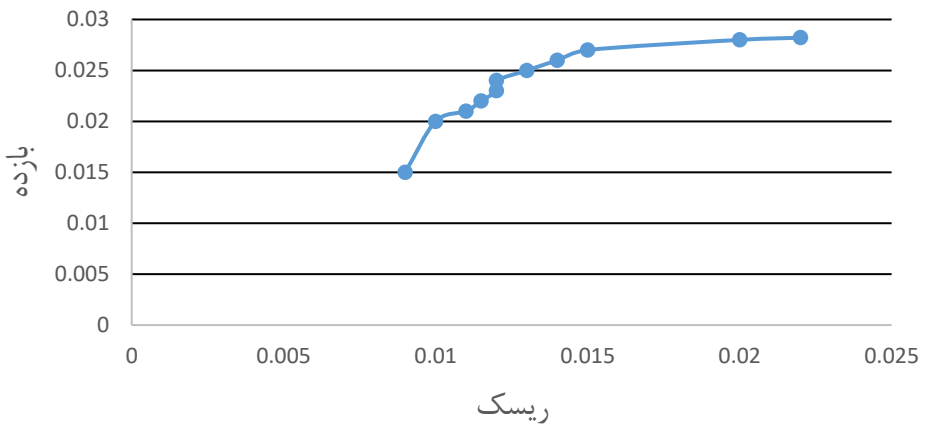

شکل ۴-۹- مزر کارا با استفاده از رگرسیون بردار پشتیبان چندگانه

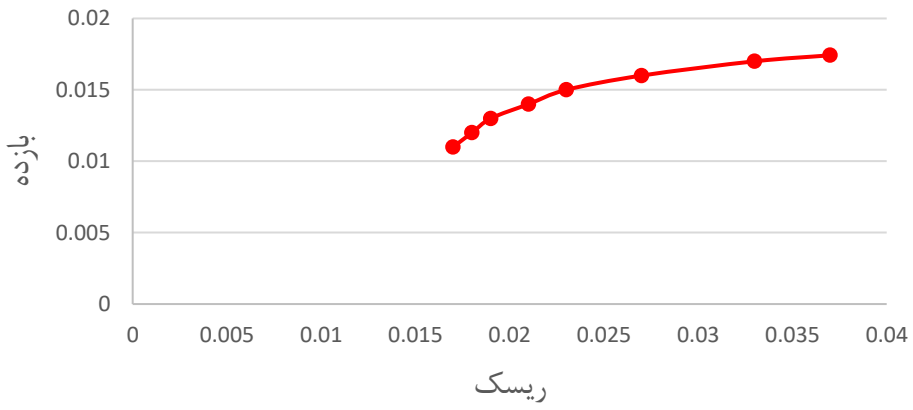

شکل ۴-۱۰- مزر کارا با استفاده از رگرسیون بردار پشتیبان یکتا

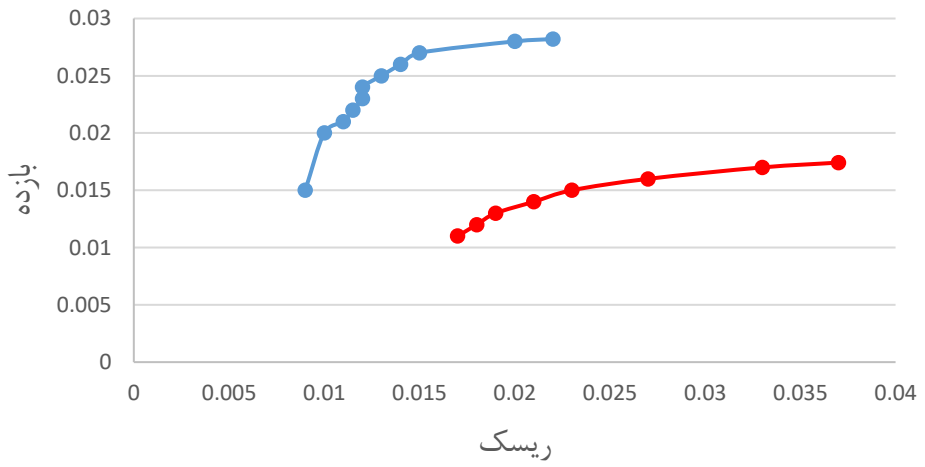

شکل ۴-۱۱- مقایسه مزر کارا دو رویکرد

۴-۴- مقایسه نتایج حل دو مدل ارائه شده با یکدیگر

پس از بدست آوردن وزن‌ها، بازده و ریسک پرتفوی معیار ارزیابی عملکرد محاسبه می‌شود. از معیار شارپ به منظور ارزیابی عملکرد پرتفوی استفاده می‌گردد. معیار شارپ یا نسبت بازده به تغییرپذیری، بازده را

نسبت به ریسک کل سبد اندازه‌گیری می‌کند. به عبارتی، از تقسیم متوسط بازده مازاد پرتفوی بر انحراف معیار بدست می‌آید (راعی و همکاران، ۱۴۰۰). این معیار به صورت زیر تعریف می‌گردد:

$$SH_p = \frac{R_p - R_f}{\sigma_p} \qquad (۱-۴)$$

مقدار R_f نشان‌دهنده بازده بدون ریسک، R_p نشان‌دهنده بازده پرتفوی و σ_p نشان دهنده ریسک یا انحراف معیار پرتفوی می‌باشد. به منظور بررسی عملکرد، دو پرتفوی به نام A و B نامگذاری می‌شوند که در پرتفوی A وزن‌های سرمایه‌گذاری مبتنی بر رگرسیون بردار پشتیبان با خروجی چندگانه و در پرتفوی B وزن‌های سرمایه‌گذاری مبتنی بر رگرسیون بردار پشتیبان با خروجی یکتا استخراج گردیده‌اند. براساس این وزن‌ها، بازده مورد انتظار پرتفوی و ریسک بر اساس معیار شارپ برای مقایسه پرتفوها در نظر گرفته می‌شوند. ذکر این نکته لازم است که تنها پرتفوهایی را مورد بررسی قرار می‌دهیم که مطابق شکل ۴-۱۱ دارای ریسک یکسان باشند. همچنین مقدار بازده بدون ریسک برای محاسبه معیار شارپ ۱درصد درنظر گرفته شده است.

جدول ۴-۱۰- مقایسه نسبت‌های شارپ

نسبت شارپ پرتفوهای نوع A با نرخ بهره بدون ریسک ۱٪	نسبت شارپ پرتفوهای نوع B با نرخ بهره بدون ریسک ۱٪
۰.۰۱۱	۰.۱
۰.۲	۰.۹
۰.۲۲	۰.۸۲

براساس اطلاعات بدست آمده مشاهده می‌شود که معیار شارپ محاسبه شده پرتفوی A از پرتفوی B بیشتر است، در نتیجه پرتفوی A طبق معیار شارپ عملکرد بالاتری را برای سرمایه‌گذار به دنبال دارد. همچنین نمودارهای مرز کارا نشان می‌دهد که بهینه سازی سبد سهام مبتنی بر پیش‌بینی با استفاده از رگرسیون بردار پشتیبان چندگانه در مقایسه با بهینه سازی سبد سهام مبتنی بر پیش‌بینی با استفاده از رگرسیون بردار پشتیبان یکتا به دلیل در نظر گرفتن روابط و همبستگی بین سهام، بازده بالاتری را نسبت به ریسک یکسان و حتی کمتردارا می‌باشد.

۴-۵- جمع بندی

در این فصل جهت ارزیابی مدل پیشنهادی در فصل سوم به حل یک مثال عددی با استفاده از آن پرداخته شد. با استفاده از داده‌های واقعی بازار سهام شاخص S&P۵۰۰ مسئله بهینه‌سازی سبد سهام مورد حل قرار گرفت. این امر ملزم به پیش‌بینی بازده سهام برای دوره آتی بود و بدین منظور از رگرسیون بردار پشتیبان با خروجی چندگانه استفاده گردید. در ادامه نتایج حاصل از حل مدل پیشنهادی مورد بررسی و مقایسه قرار گرفت. در فصل پیش رو نیز به جمع بندی مطالب پژوهش و پیشنهاداتی برای پژوهش‌های آتی پرداخته می‌شود.

فصل پنجم

نتیجه‌گیری و پیشنهادات برای تحقیقات آتی

۵-۱- مقدمه

در این بخش نتیجه گیری و جمع بندی مباحث ذکر شده در این پایان نامه مطرح می‌شود. در انتها نیز پیشنهاداتی برای پژوهش‌های آتی ارائه شده است.

۵-۲- جمع بندی تحقیق

هدف از مدیریت پرتفوی، انتخاب بهینه سبد سهام می‌باشد. این انتخاب بهینه باید راهنمایی برای سرمایه‌گذاران در جهت دستیابی به بیشترین بازده در برابر کمترین ریسک ممکن جهت سرمایه‌گذاری باشد. از سوی دیگر یکی از عوامل مؤثر در تصمیم‌گیری‌های سرمایه‌گذاری، قیمت سهام بوده و پیش‌بینی آن می‌تواند نقشی مؤثر را ایفا کند. جهت پیش‌بینی قیمت سهام معمولاً از مدل‌هایی هوشمند غیرخطی مانند رگرسیون بردار پشتیبان که خطای پیش‌بینی کمتری نسبت به مدل‌های کلاسیک دارد، استفاده می‌شود. از این رو در این پژوهش مدل غیرخطی رگرسیون بردار پشتیبان توسعه داده شد. در همین راستا جهت انتخاب سبد سهام بهینه از نتایج الگوریتم ماشین بردار پشتیبان با خروجی چندگانه به صورت همزمان و یک مدل تشکیل پرتفوی استفاده شد. برای نشان دادن کارایی مدل مورد استفاده از داده‌های صنایع مختلف شاخص S&P۵۰۰ در دوره زمانی ۲۰۱۶/۱۲/۰۹ تا ۲۰۲۱/۰۲/۰۸ به صورت هفتگی استفاده گردید.

در این پژوهش عملکرد ماشین بردار پشتیبان چندگانه در مقایسه با ماشین بردار یکتا به منظور پیش‌بینی در بازه زمانی ۲۰۲۰/۱۳/۰۷ تا ۲۰۲۱/۰۲/۰۸ مورد بررسی قرار گرفت. نتایج حاصل از خطای پیش‌بینی رویکردهای مذکور به کمک میانگین مربع خطا، میانگین قدر مطلق خطا و ریشه دوم میانگین مربع خطا مورد مقایسه قرار گرفت.

نتایج نشان می‌دهد که ماشین بردار پشتیبان چندگانه پیش‌بینی را با خطای کمتری انجام داده است. بنابریان زمانی که بین متغیرهای خروجی نوعی وابستگی برقرار باشد، نمی‌توان از چندین پیش‌بینی با خروجی یکتا استفاده نمود چرا که این روش شامل بکارگیری چندین ماشین بردار پشتیبان برای چنین مسائلی است که عیب آن نادیده گرفتن روابط و وابستگی بین خروجی‌ها می‌باشد. لذا می‌توان به منظور پیش‌بینی جهت افزایش دقت این ابزار را توصیه نمود.

همچنین بهینه سازی سبد سهام مبتنی بر پیش‌بینی با استفاده از رگرسیون بردار پشتیبان چندگانه در مقایسه با بهینه سازی سبد سهام مبتنی بر پیش‌بینی با استفاده از رگرسیون بردار پشتیبان یکتا به دلیل در نظر گرفتن روابط و همبستگی بین سهام، طبق نمودار ۴-۳ و نسبت شارپ دارای عملکرد بالاتر می‌باشد. طبق نتایج پژوهش می‌توان گفت که بهینه سازی سبد سهام با مدل مذکور به عنوان یک مدل نوین می‌تواند در انتخاب پرتفوی، مؤثر واقع شده و به عملکرد بهتری منتهی گردد.

۵-۳- خلاصه‌ای از پایان نامه

مطالب ذکر شده در فصل‌های مختلف این پایان نامه به شرح زیر می‌باشد:

در فصل ابتدایی به تعریف مسئله، اهمیت موضوع، هدف و جنبه‌های نوآوری و جدید بودن پژوهش که موجب تمایز این پایان نامه از دیگر پایان‌نامه‌های صورت گرفته در این زمینه شده است، ارائه گردید.

در فصل دوم، اصطلاحات، مفاهیم و تعاریف موردنیاز به منظور ورود به بحث و آشنایی که شامل توضیحات در زمینه انتخاب بهینه سبد سرمایه، پیش‌بینی و رگرسیون بردار پشتیبان بودند، مطرح شد. به دنبال هر یک از مفاهیم، کاربرد و ادبیات آن در مسئله انتخاب سبد سهام نیز مطرح گردید.

در فصل سوم با استفاده از مفاهیم ارائه شده در زمینه پیش‌بینی و در راستای کاربردی‌تر کردن و بهبود مدل پیشین رگرسیون بردار پشتیبان، رگرسیون بردار پشتیبان با خروجی چندگانه معرفی و مفصل شرح گردید.

در فصل چهارم نیز مدل پیشنهادی انتخاب بهینه سبد سهام مبتنی بر پیش‌بینی با استفاده از رگرسیون بردار پشتیبان با خروجی چندگانه به کمک داده‌های واقعی سهام موجود در شاخص S&P۵۰۰ مورد آزمایش و بررسی قرار گرفت. برای این منظور ابتدا ۷ سهام از صنایع مختلف جهت سرمایه‌گذاری انتخاب شدند. در ادامه با استفاده از رگرسیون بردار پشتیبان به پیش‌بینی بازده آتی سهام منتخب پرداخته و از آنان در انتخاب بهینه سبد سهام استفاده نمودیم. در ادامه نیز نتایج حاصل مورد بررسی و تفسیر قرار گرفتند.

۵-۴- پیشنهادات برای تحقیقات آتی

با توجه به مطالعات صورت گرفته در این پایان نامه بر روی مسئله انتخاب سبد سهام پیشنهاداتی برای پژوهش‌های آتی به صورت خلاصه ارائه می‌گردد:

۱) در نظر گرفتن انواع بازارهای مالی به منظور پیش‌بینی و سرمایه‌گذاری که دارای همبستگی هستند.
۲) استفاده از رویکرد سرمایه‌گذاری ردیابی شاخص به منظور انتخاب بهینه سبد سهام با استفاده از داده‌های پیش‌بینی شده می‌تواند صورت بگیرد.

۳) استفاده از رویکرد بهینه سازی استوار در انتخاب بهینه سبد سهام با استفاده از داده‌های پیش‌بینی شده نیز می‌تواند صورت بگیرد.

فهرست منابع

آزادی، امیر. نجفی، امیرعباس. ۲۰۲۰، مدل بهبود یافته ردیابی شاخص با درنظر گرفتن هزینه‌های معاملاتی. *مهندسی مالی و مدیریت اوراق بهادار*، ۱۱(۴۲)، ۲۳-۴۳.

احمدی، محمد. ابرهیم نژاد، علی. سرزعیم، علی. حیاتی، طاهره و اسلامیان، حمید. (۱۳۹۳). آمادگی آزمون تحلیل‌گری بازار سرمایه. تهران: انتشارات آریانا قلم.

بیات، علی. اسدی، لیدا. ۲۰۱۷، بهینه سازی پرتفوی سهام: سودمندی الگوریتم پرندگان و مدل مارکویتز. *مهندسی مالی و مدیریت اوراق بهادار*، ۸(۳۲) ، ۶۳-۸۵.

حبیب زاده، ایزدپور، مصطفی. ۲۰۲۰، پیش‌بینی سودآوری با رویکرد شبکه عصبی و مقایسه آن با ماشین بردار پشتیبان (svm) و درخت‌تصمیم C۵. *دانش مالی تحلیل اوراق بهادار*, ۱۳(۴۶), ۳۹-۵۶.

خواجه زاده، سامیران. شاهوردیانی، شادی و دانشور، معدنچی زاج. (۲۰۲۰). پیش بینی سبد بهینه سهام رویکرد الگوریتم فراابتکاری و فرآیند تصمیم مارکوف. *تصمیم گیری و تحقیق در عملیات*, ۵(۴), ۴۲۶-۴۴۵.

راعی, باجلان. سعید, عجم. (۲۰۲۱). بررسی کارایی مدل N/۱ در انتخاب پرتفوی. *تحقیقات مالی*، ۲۳(۱)، ۱-۱۶.

زمانی, محسن. افسر, ثقفی و سید وحید, بیات. (۲۰۱۴). سیستم خبره پیش بینی قیمت سهام و بهینه سازی سبد سهام با استفاده از شبکه‌های عصبی فازی، مدل سازی فازی و الگوریتم ژنتیک. *مهندسی مالی و مدیریت اوراق بهادار*, ۵(۲۱), ۱۰۷-۱۳۰.

باجلان، سعید. فلاحپور، سعید و دانا، ناهید. (۲۰۱۷). پیش‌بینی روند قیمت سهام با استفاده از ماشین بردار پشتیبان تعدیل‌یافته همراه با انتخاب ویژگی هیبرید. *چشم انداز مدیریت مالی*.

فلاح پور سعید, گل ارضی غلامحسین, فتوره چیان ناصر. پیش بینی روند حرکتی قیمت سهام با استفاده از ماشین بردار پشتیبان بر پایه ژنتیک در بورس اوراق بهادار تهران.

Awad, M., & Khanna, R. (٢٠١٥). Efficient learning machines: *theories, concepts, and applications for engineers and system designers* (p. ٢٦٨). Springer nature.

Borchani, H., Varando, G., Bielza, C., & Larranaga, P. (٢٠١٥). A survey on multi-output regression. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, ٥(٥), ٢١٦-٢٣٣

Burnham, A. J., MacGregor, J. F., & Viveros, R. (١٩٩٩). Latent variable multivariate regression modeling. *Chemometrics and Intelligent Laboratory Systems*, ٤٨(٢), ١٦٧-١٨٠.

Chen, W., Zhang, H., Mehlawat, M. K., & Jia, L. (٢٠٢١). Mean–variance portfolio optimization using machine learning-based stock price prediction. *Applied Soft Computing*, ١٠٠, ١٠٦٩٤٣.

Cortes, C., & Vapnik, V. (١٩٩٥). Support-vector networks. *Machine learning*, ٢٠(٣), ٢٧٣-٢٩٧.

de Freitas, F. D., De Souza, A. F., & de Almeida, A. R. (٢٠٠٦). A prediction-based portfolio optimization model. *In Proc. 5st Int. Symp. Robot. Automat*. (pp. ٥٢٠-٥٢٥).

Deng, Y. F., Jin, X., & Zhong, Y. X. (٢٠٠٥, August). Ensemble SVR for prediction of time series. In *2005 International Conference on Machine Learning and Cybernetics* (Vol. ٦, pp. ٣٥٢٨-٣٥٣٤). IEEE.

Drucker, H., Burges, C. J., Kaufman, L., Smola, A., & Vapnik, V. (١٩٩٧). Support vector regression machines. *Advances in neural information processing systems*, ٩, ١٥٥-١٦١.

Esfahani, H. N., hossein Sobhiyah, M., & Yousefi, V. R. (٢٠١٦). Project portfolio selection via harmony search algorithm and modern portfolio theory. *Procedia-Social and Behavioral Sciences*, ٢٢٦, ٥١-٥٨.

Fabozzi, F. J., Neave, E. H., & Zhou, G. (٢٠١١). *Financial economics.* Wiley.

Fischer, D. E., & Jordan, R. J. (١٩٧٥). Security analysis and portfolio management.

Freitas, F. D., De Souza, A. F., & de Almeida, A. R. (٢٠٠٩). Prediction-based portfolio optimization model using neural networks. *Neurocomputing*, *72*(١٠-١٢), ٢١٥٥-٢١٧٠.

Gökgöz, F., & Atmaca, M. E. (٢٠١٢). Financial optimization in the Turkish electricity market: Markowitz's *mean-variance approach. Renewable and Sustainable Energy Reviews*, ١٦(١), ٣٥٧-٣٦٨

Han, Z., Liu, Y., Zhao, J., & Wang, W. (٢٠١٢). Real time prediction for converter gas tank levels based on multi-output least square support vector regressor. *Control Engineering Practice*, ٢٠(١٢), ١٤٠٠-١٤٠٩.

Hao, C., Wang, J., Xu, W., & Xiao, Y. (٢٠١٣, November). Prediction-based portfolio selection model using support vector machines. *In 2013 Sixth International Conference on Business Intelligence and Financial Engineering* (pp. ٥٦٧-٥٧١). IEEE.

Lin, K., Lin, Q., Zhou, C., & Yao, J. (٢٠٠٧, August). Time series prediction based on linear regression and SVR. In *Third International Conference on Natural Computation* (ICNC ٢٠٠٧) (Vol. ١, pp. ٦٨٨-٦٩١). IEEE.

Ma, Y., Han, R., & Wang, W. (٢٠٢١). Portfolio optimization with return prediction using deep learning and machine learning. *Expert Systems with Applications*, ١٦٥, ١١٣٩٧٣.

Markowitz, H. (١٩٥٩). Portfolio selection.

Mishra, S. K., Panda, G., & Majhi, B. (٢٠١٦). Prediction based mean-variance model for constrained portfolio assets selection using multiobjective evolutionary algorithms. *Swarm and Evolutionary Computation*, ٢٨, ١١٧-١٣٠.

Müller, K. R., Smola, A. J., Rätsch, G., Schölkopf, B., Kohlmorgen, J., & Vapnik, V. (١٩٩٧, October). Predicting time series with support vector machines. In *International Conference on Artificial Neural Networks* (pp. ٩٩٩-١٠٠٤). Springer, Berlin, Heidelberg.

Nedaie, A., & Najafi, A. A. (٢٠١٦). Polar support vector machine: Single and multiple outputs. *Neurocomputing*, ١٧١, ١١٨-١٢٦.

Nedaie, A., & Najafi, A. A. (٢٠١٨). Support vector machine with Dirichlet feature mapping. *Neural Networks*, ٩٨, ٨٧-١٠١.

Pinto, D. D. D., Monteiro, J. G. M. S., & Nakao, E. H. (٢٠١١). An approach to portfolio selection using an ARX predictor for securities' risk and return. *Expert Systems with Applications*, ٣٨(١٢), ١٥٠٠٩-١٥٠١٣.

Pisner, D. A., & Schnyer, D. M. (٢٠٢٠). Support vector machine. In *Machine Learning* (pp. ١٠١-١٢١). Academic Press.

Sánchez-Fernández, M., de-Prado-Cumplido, M., Arenas-García, J., & Pérez-Cruz, F. (٢٠٠٤). SVM multiregression for nonlinear channel estimation in multiple-input multiple-output systems. *IEEE transactions on signal processing*, ٥٢(٨), ٢٢٩٨-٢٣٠٧.

Suykens, J. A., Van Gestel, T., & De Brabanter, J. (٢٠٠٢). *Least squares support vector machines*. World scientific.

Thissen, U. V. B. R., Van Brakel, R., De Weijer, A. P., Melssen, W. J., & Buydens, L. M. C. (٢٠٠٣). Using support vector machines for time series *prediction. Chemometrics and intelligent laboratory systems*, ٦٩(١-٢), ٣٥-٤٩.

Vazquez, E., & Walter, E. (٢٠٠٣). Multi-output suppport vector regression. *IFAC Proceedings Volumes*, ٣٦(١٦), ١٧٨٣-١٧٨٨.

Xia, Y., Liu, B., Wang, S., & Lai, K. K. (٢٠٠٠). A model for portfolio selection with order of expected returns. *Computers & Operations Research*, ٢٧(٥), ٤٠٩-٤٢٢.

Xu, S., An, X., Qiao, X., & Zhu, L. (٢٠١٤). Multi-task least-squares support vector machines. *Multimedia tools and applications*, ٧١(٢), ٦٩٩-٧١٥.

Xu, S., An, X., Qiao, X., Zhu, L., & Li, L. (٢٠١٣). Multi-output least-squares support vector regression machines. *Pattern Recognition Letters*, ٣٤(٩), ١٠٧٨-١٠٨٤.

Yang, F., Chen, Z., Li, J., & Tang, L. (٢٠١٩). A novel hybrid stock selection method with stock prediction. *Applied Soft Computing, 80*, ٨٢٠-٨٣١.

Zhang, W., Liu, X., Ding, Y., & Shi, D. (٢٠١٢, July). Multi-output LS-SVR machine in extended feature space. In *2012 IEEE International Conference on Computational Intelligence for Measurement Systems and Applications (CIMSA) Proceedings* (pp. ١٣٠-١٣٤). IEEE

Abstract

With the growth and development of the global economy and its competitiveness, the decision regarding the optimal allocation of resources has become more important than ever. In addition to being a reflection of the economic situation of countries, the stock exchange is a place for investors to invest their resources to increase their wealth. Since reducing risk and increasing the return on investment in the stock market has always been the most important and fundamental concern of investors, in the financial literature, investing in the stock portfolio has been suggested to reduce risk. On the other hand, one of the influential factors in investment decisions is the stock price, and the selection of the stock portfolio as an investment program, in addition to the past product of the stock, must also consider the future potential of the stock, so the importance of price forecasting. Stocks are becoming more apparent. Because the stock market is fundamentally dynamic, complex, nonlinear and non-parametric and is affected by many economic and non-economic factors and variables, choosing the best and most efficient model to predict the nonlinear nature of stock data has always been necessary, difficult and challenging. Is. In addition, past research has shown that the use of traditional prediction methods has higher error and poorer performance compared to newer methods and nonlinear models. In this regard, in this study, one of the artificial intelligence methods called support vector regression with multiple outputs has been used to predict stock prices, and then with the predicted data to optimize the stock portfolio. Finally, the results are compared with the results of the optimal selection of stock portfolio based on forecasting with simple support vector regression.

Keywords: Portfolio Selection, Stock Price Prediction, Support Vector Machine, Multiple Output Regression,

K. N. Toosi University of Technology
Department of Industrial Engineering

Prediction_Based Portfolio Selection Model using Support Vector Regression

Mohammad Amin Monadi

Supervisor:
Dr. Amir Abbas Najafi

Master's Thesis in Industrial Engineering Majoring in Financial Engineering

September ۲۰۲۱